

# Modelos de Regressão e Previsão

## Modelo de Regressão Linear Simples: Estimação

Prof. Carlos Trucíos  
carlos.trucios@facc.ufrj.br  
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis  
Universidade Federal do Rio de Janeiro

## Aula 2

# MRLS: Estimação

# MRLS: Estimação

Na prática, nunca conhecemos os valores de  $\beta_0, \beta_1$  então precisamos estima-los utilizando os dados. Estes valores estimados serão denotados por  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , respectivamente.

# MRLS: Estimação

Na prática, nunca conhecemos os valores de  $\beta_0, \beta_1$  então precisamos estima-los utilizando os dados. Estes valores estimados serão denotados por  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , respectivamente.


Sejam  $(x_1, y_1), \dots, (x_n, y_n)$  uma amostra aleatória (a.a.) de tamanho  $n$  da população, então

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

onde  $i$  indica a  $i$ -ésima observação.

# MRLS: Estimação

Estamos interessados numa reta do tipo:



# Métodos de estimação

- Usaremos as suposições descritas na aula anterior:

# Métodos de estimação

- Usaremos as suposições descritas na aula anterior:
- $E(u) = 0$

# Métodos de estimação

- Usaremos as suposições descritas na aula anterior:
- $E(u) = 0$
- $Cov(xu) = E(xu) = 0$  (consequencia de  $E(u|x) = E(u)$ )



## Métodos de estimação

- Usaremos as suposições descritas na aula anterior:
- $E(u) = 0$
- $Cov(xu) = E(xu) = 0$  (consequencia de  $E(u|x) = E(u)$ )
- Então,

$$E(u) = E(y - \beta_0 - \beta_1 x) = 0$$

e

$$E(xu) = E(x(y - \beta_0 - \beta_1 x)) = 0$$

## Métodos de estimação

- Usaremos as suposições descritas na aula anterior:
- $E(u) = 0$
- $Cov(xu) = E(xu) = 0$  (consequencia de  $E(u|x) = E(u)$ )
- Então,

$$E(u) = E(y - \beta_0 - \beta_1 x) = 0$$

e

$$E(xu) = E(x(y - \beta_0 - \beta_1 x)) = 0$$

# Métodos de estimação

- Usaremos as suposições descritas na aula anterior:
- $E(u) = 0$
- $Cov(xu) = E(xu) = 0$  (consequencia de  $E(u|x) = E(u)$ )
- Então,

$$E(u) = E(y - \beta_0 - \beta_1 x) = 0$$

e

$$E(xu) = E(x(y - \beta_0 - \beta_1 x)) = 0$$

## Método dos momentos

Resolver o sistema resultante de igualar os momentos populacionais com os momentos amostrais

# Métodos de estimação: MM

## Método dos Momentos (MM)

$$n^{-1} \sum_{i=1}^n \hat{u}_i = n^{-1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = E(u) = 0 \quad (1)$$

$$n^{-1} \sum_{i=1}^n x_i \hat{u}_i = n^{-1} \sum_{i=1}^n (x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)) = E(xu) = 0 \quad (2)$$

# Métodos de estimação: MM

## Método dos Momentos (MM)

$$n^{-1} \sum_{i=1}^n \hat{u}_i = n^{-1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = E(u) = 0 \quad (1)$$

$$n^{-1} \sum_{i=1}^n x_i \hat{u}_i = n^{-1} \sum_{i=1}^n (x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)) = E(xu) = 0 \quad (2)$$

Então, de (1)

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

(1) e (2) são chamadas **condições de primeira ordem**

# Métodos de estimação: MM

## Método dos Momentos (MM)

$$n^{-1} \sum_{i=1}^n \hat{u}_i = n^{-1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = E(u) = 0 \quad (1)$$

$$n^{-1} \sum_{i=1}^n x_i \hat{u}_i = n^{-1} \sum_{i=1}^n (x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)) = E(xu) = 0 \quad (2)$$

Então, de (1)

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

(1) e (2) são chamadas **condições de primeira ordem**

Das condições de primeira ordem temos que  $\bar{\hat{u}} = 0$  e  $cov(x, \hat{u}) = 0$

## Métodos de estimação: MM

De (2),

$$\sum_{i=1}^n [x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)] = \sum_{i=1}^n [x_i(y_i - \underbrace{(\bar{y} - \hat{\beta}_1 \bar{x})}_{\hat{\beta}_0} - \hat{\beta}_1 x_i)] = 0 \times n = 0$$

## Métodos de estimação: MM

De (2),

$$\sum_{i=1}^n [x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)] = \sum_{i=1}^n [x_i(y_i - \underbrace{(\bar{y} - \hat{\beta}_1 \bar{x})}_{\hat{\beta}_0} - \hat{\beta}_1 x_i)] = 0 \times n = 0$$

Então,

$$\sum_{i=1}^n [x_i(y_i - \bar{y})] - \hat{\beta}_1 \sum_{i=1}^n [x_i(x_i - \bar{x})] = 0$$



## Métodos de estimação: MM

De (2),

$$\sum_{i=1}^n [x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)] = \sum_{i=1}^n [x_i(y_i - \underbrace{(\bar{y} - \hat{\beta}_1 \bar{x})}_{\hat{\beta}_0} - \hat{\beta}_1 x_i)] = 0 \times n = 0$$

Então,

$$\sum_{i=1}^n [x_i(y_i - \bar{y})] - \hat{\beta}_1 \sum_{i=1}^n [x_i(x_i - \bar{x})] = 0$$

Logo,

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n [x_i(y_i - \bar{y})]}{\sum_{i=1}^n [x_i(x_i - \bar{x})]} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

# Métodos de estimação: MM

Então,

## Estimadores MM

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{cov}(x, y)}{\text{var}(x)} = \hat{\rho}_{xy} \frac{\hat{\sigma}_y}{\hat{\sigma}_x}$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Desde que  $\sum_{i=1}^n (x_i - \bar{x})^2 > 0$ .

Onde

- $\hat{\rho}_{xy}$  é a correlação amostral entre  $x$  e  $y$ ;
- $\hat{\sigma}_x$  é o desvio padrão amostral de  $x$  e
- $\hat{\sigma}_y$  é o desvio padrão amostral de  $y$ .


## Métodos de estimação: MM - Apêndice

$$\begin{aligned}
 \textcircled{1} \quad & \sum_{i=1}^n [x_i(x_i - \bar{x})] = \sum_{i=1}^n (x_i - \bar{x})^2? \\
 & \sum_{i=1}^n [x_i(x_i - \bar{x})] = \sum_{i=1}^n [(x_i - \bar{x} + \bar{x})(x_i - \bar{x})] = \\
 & \sum_{i=1}^n (x_i - \bar{x})^2 + \underbrace{\bar{x} \sum_{i=1}^n (x_i - \bar{x})}_0
 \end{aligned}$$

$$\begin{aligned}
 \textcircled{2} \quad & \sum_{i=1}^n [x_i(y_i - \bar{y})] = \sum_{i=1}^n [(x_i - \bar{x})(y_i - \bar{y})]? \\
 & \sum_{i=1}^n [x_i(y_i - \bar{y})] = \sum_{i=1}^n [(x_i - \bar{x} + \bar{x})(y_i - \bar{y})] = \\
 & \sum_{i=1}^n [(x_i - \bar{x})(y_i - \bar{y})] + \underbrace{\sum_{i=1}^n [\bar{x}(y_i - \bar{y})]}_{\bar{x} \sum_{i=1}^n (y_i - \bar{y})} = \sum_{i=1}^n [(x_i - \bar{x})(y_i - \bar{y})]
 \end{aligned}$$

# Métodos de estimação: MQO

## Mínimos Quadrados Ordinarios (MQO)



## Métodos de estimação: MQO

Outra forma de obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$  é através de MQO.

- A ideia é minimizar a soma dos quadrados dos resíduos  $\hat{u}_i$  onde  $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

## Métodos de estimação: MQO

Outra forma de obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$  é através de MQO.

- A ideia é minimizar a soma dos quadrados dos resíduos  $\hat{u}_i$  onde  $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

- Seja  $SQR = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$ , então

$$\hat{\beta}_0, \hat{\beta}_1 = \underset{b_0, b_1}{\operatorname{argmin}} SQR$$

# Métodos de estimação: MQO

Outra forma de obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$  é através de MQO.

- A ideia é minimizar a soma dos quadrados dos resíduos  $\hat{u}_i$  onde  $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

- Seja  $SQR = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$ , então

$$\hat{\beta}_0, \hat{\beta}_1 = \underset{b_0, b_1}{\operatorname{argmin}} SQR$$

- Derivando w.r.t  $b_0$  e  $b_1$  temos

$$\frac{\partial SQR}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i); \quad \frac{\partial SQR}{\partial b_1} = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i)$$

# Métodos de estimação: MQO

Outra forma de obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$  é através de MQO.

- A ideia é minimizar a soma dos quadrados dos resíduos  $\hat{u}_i$  onde  $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

- Seja  $SQR = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$ , então

$$\hat{\beta}_0, \hat{\beta}_1 = \underset{b_0, b_1}{\operatorname{argmin}} SQR$$

- Derivando w.r.t  $b_0$  e  $b_1$  temos

$$\frac{\partial SQR}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i); \quad \frac{\partial SQR}{\partial b_1} = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i)$$

- Igualando a zero, chegamos ao mesmo sistema nas Equações (1) e (2).



## Métodos de estimação: MQO

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \text{ e } \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

***Como sabemos que de fato são os valores que minimizam SQR?***

## Métodos de estimação: MQO

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \text{ e } \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

***Como sabemos que de fato são os valores que minimizam SQR?***

A matriz 
$$\begin{bmatrix} \frac{\partial^2 SQR}{\partial b_0^2} & \frac{\partial^2 SQR}{\partial b_0 \partial b_1} \\ \frac{\partial^2 SQR}{\partial b_1 \partial b_0} & \frac{\partial^2 SQR}{\partial b_1^2} \end{bmatrix}$$
 deve ser definida positiva (**todos os autovalores devem ser positivos**)

## Métodos de estimação: MQO

Uma vez obtidos  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , podemos obter **y chapéu**

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

( $\hat{y}$ : valores ajustados/previstos da regressão)

## Métodos de estimação: MQO

Uma vez obtidos  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , podemos obter **y chapéu**

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

( $\hat{y}$ : valores ajustados/previstos da regressão)

Veja que

$$\Delta \hat{y} = \hat{\beta}_1 \Delta x \text{ ou equivalentemente } \hat{\beta}_1 = \Delta \hat{y} / \Delta x$$

## Métodos de estimação: MQO

Uma vez obtidos  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , podemos obter **y chapéu**

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

( $\hat{y}$ : valores ajustados/previstos da regressão)

Veja que

$$\Delta \hat{y} = \hat{\beta}_1 \Delta x \text{ ou equivalentemente } \hat{\beta}_1 = \Delta \hat{y} / \Delta x$$

*$\hat{\beta}_1$  nos diz quanto varia  $\hat{y}$  quando  $x$  aumenta em uma unidade*

## Exemplos no R

## Exemplos no R: salarios CEO

Informações sobre o *salario* (anual em milhares de dólares) e o retorno médio sobre o patrimônio líquido dos últimos 3 anos, *roe* (definido como uma porcentagem do patrimônio líquido) de 209 CEOs estão disponíveis no arquivo **ceosal1.txt**.

Queremos estudar a relação

$$\text{salario} = \beta_0 + \beta_1 \text{roe} + u$$

## Exemplos no R: salarios CEO

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,4)]  
colnames(CEOSAL1) = c("salario", "roe")  
head(CEOSAL1,3)
```

```
##      salario  roe  
## 1      1095 14.1  
## 2      1001 10.9  
## 3      1122 23.5
```



## Exemplos no R: salarios CEO

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,4)]  
colnames(CEOSAL1) = c("salario", "roe")  
head(CEOSAL1,3)
```

```
##      salario  roe  
## 1      1095 14.1  
## 2      1001 10.9  
## 3      1122 23.5
```

- Para o CEO 1, temos um salário anual de 1095.000 USD e um retorno médio sobre o patrimônio líquido de 14.1%
- Para o CEO 2, temos um salário anual de 1001.000 USD e um retorno médio sobre o patrimônio líquido de 10.9%

## Exemplos no R: salarios CEO

```
summary(CEOSAL1)
```

| ## | salario       | roe           |
|----|---------------|---------------|
| ## | Min. : 223    | Min. : 0.50   |
| ## | 1st Qu.: 736  | 1st Qu.:12.40 |
| ## | Median : 1039 | Median :15.50 |
| ## | Mean : 1281   | Mean :17.18   |
| ## | 3rd Qu.: 1407 | 3rd Qu.:20.00 |
| ## | Max. :14822   | Max. :56.30   |

## Exemplos no R: salarios CEO

$$\hat{\beta}_1 = \frac{\text{cov}(x, y)}{\text{var}(x)} = \hat{\rho} \frac{\hat{\sigma}_y}{\hat{\sigma}_x} \quad \text{e} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

```
# betas (hat)
```

```
b1_hat = cov(CEOSAL1)[1,2]/var(CEOSAL1$roe)
```

```
b0_hat = mean(CEOSAL1$salario) - b1_hat*mean(CEOSAL1$roe)
```

```
c(b0_hat, b1_hat)
```

```
## [1] 963.19133 18.50119
```

```
# Outra forma beta1_hat
```

```
cor(CEOSAL1)[1,2]*(sd(CEOSAL1$salario)/sd(CEOSAL1$roe))
```

```
## [1] 18.50119
```

## Exemplos no R: salarios CEO

```
lm(salario~roe, data = CEOSAL1)
```

```
##
```

```
## Call:
```

```
## lm(formula = salario ~ roe, data = CEOSAL1)
```

```
##
```

```
## Coefficients:
```


```
## (Intercept)          roe
```

```
##          963.2          18.5
```

$$\widehat{\text{salario}} = 963.2 + 18.5 \text{ roe}$$

*Se o roe aumentar 1%, espera-se que o salario anual aumente em 18.500 USD.*

# Exemplos no R: salarios CEO



## Exemplos no R: resultados eleitorais US

Os gastos de campanha de 173 disputas eleitorais entre dois partidos para o *House of Representatives dos US* estão contidos no arquivo **vote1.txt**. *votosA* representa a porcentagem de votos recebidos pelo candidato A (Há apenas 2 candidatos A e B em cada disputa) e *despesasA* representa a porcentagem das despesas totais em campanha do total que cabe ao candidato A.

## Exemplos no R: resultados eleitorais US

```
VOTE1 = read.table("./DadosMRP/vote1.txt")[,c(4,10)]  
colnames(VOTE1) = c("votosA", "despesasA")  
head(VOTE1,3)
```

```
##      votosA despesasA  
## 1         68      97.41  
## 2         62      60.88  
## 3         73      97.01
```

## Exemplos no R: resultados eleitorais US

```
VOTE1 = read.table("./DadosMRP/vote1.txt")[,c(4,10)]  
colnames(VOTE1) = c("votosA", "despesasA")  
head(VOTE1,3)
```

```
##      votosA despesasA  
## 1         68      97.41  
## 2         62      60.88  
## 3         73      97.01
```

- Obs1: Candidato A obteve 68% dos votos e gastou o 97.41% do assignado para a campanha.
- Obs2: Candidato A obteve 62% dos votos e gastou o 60.88% do assignado para a campanha.



## Exemplos no R: resultados eleitorais US

```
summary(VOTE1)
```

| ## | votosA       | despesasA     |
|----|--------------|---------------|
| ## | Min. :16.0   | Min. : 0.09   |
| ## | 1st Qu.:36.0 | 1st Qu.:18.87 |
| ## | Median :50.0 | Median :50.85 |
| ## | Mean :50.5   | Mean :51.08   |
| ## | 3rd Qu.:65.0 | 3rd Qu.:84.26 |
| ## | Max. :84.0   | Max. :99.50   |

## Exemplos no R: resultados eleitorais US

```
lm(votosA~despesasA, data = VOTE1)
```

```
##
```

```
## Call:
```

```
## lm(formula = votosA ~ despesasA, data = VOTE1)
```

```
##
```

```
## Coefficients:
```


```
## (Intercept)      despesasA
```

```
##      26.8125          0.4638
```

$$\widehat{\text{votosA}} = 26.8125 + 0.4638 \text{ despesasA}$$

Se aumentarmos o gasto de despesas de campanha em 1%, espera-se que o candidato A receba 0.46% a mais de votos.

# Exemplos no R: resultados eleitorais US



## Qualidade de ajuste

# SQT, SQE, SQR

Temos que  $y_i - \hat{y}_i = \hat{u}_i \implies y_i = \hat{y}_i + \hat{u}_i$ , então

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n \underbrace{(y_i - \hat{y}_i + \hat{y}_i - \bar{y})}_{\hat{u}_i}^2 = \sum_{i=1}^n (\hat{u}_i + \hat{y}_i - \bar{y})^2$$

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{SQT} = \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{SQR} + \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SQE} + 2 \underbrace{\sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y})}_0$$

$$SQT = SQR + SQE$$

# Qualidade de ajuste

- Como sabemos se a variável  $x$  ajuda a explicar bem a variável  $y$ ?

# Qualidade de ajuste

- Como sabemos se a variável  $x$  ajuda a explicar bem a variável  $y$ ?
- Temos um número que nos ajude a entender quão bem a reta de regressão se ajusta aos dados é bastante útil.

# Qualidade de ajuste

- Como sabemos se a variável  $x$  ajuda a explicar bem a variável  $y$ ?
- Termos um número que nos ajude a entender quão bem a reta de regressão se ajusta aos dados é bastante útil.
- O  $R^2$  (R-quadrado) nos ajudará a responder esta pergunta.



# Qualidade de ajuste

- Como sabemos se a variável  $x$  ajuda a explicar bem a variável  $y$ ?
- Termos um número que nos ajude a entender quão bem a reta de regressão se ajusta aos dados é bastante útil.
- O  $R^2$  (R-quadrado) nos ajudará a responder esta pergunta.

## Qualidade de ajuste

- Como sabemos se a variável  $x$  ajuda a explicar bem a variável  $y$ ?
- Termos um número que nos ajude a entender quão bem a reta de regressão se ajusta aos dados é bastante útil.
- O  $R^2$  (R-quadrado) nos ajudará a responder esta pergunta.

$$SQT = SQR + SQE$$

$$1 = \frac{SQR}{SQT} + \underbrace{\frac{SQE}{SQT}}_{R^2}$$

# Qualidade de ajuste

R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

# Qualidade de ajuste

## R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

- $0 \leq R^2 \leq 1$

# Qualidade de ajuste

## R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

- $0 \leq R^2 \leq 1$
- razão entre a variação explicada e a variação total.

## Qualidade de ajuste

### R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

- $0 \leq R^2 \leq 1$
- razão entre a variação explicada e a variação total.
- $100 \times R^2$  é a porcentagem de variação de  $y$  explicada pelo modelo.

# Qualidade de ajuste

## R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

- $0 \leq R^2 \leq 1$
- razão entre a variação explicada e a variação total.
- $100 \times R^2$  é a porcentagem de variação de  $y$  explicada pelo modelo.
- $R^2$  próximo de **0** indica um ajuste **ruim**,  $R^2$  próximo de **1** indica um **bom** ajuste.

# Qualidade de ajuste

## R-quadrado ou coeficiente de determinação

$$R^2 = 1 - \frac{SQR}{SQT} = \frac{SQT - SQR}{SQT} = \frac{SQE}{SQT}$$

- $0 \leq R^2 \leq 1$
- razão entre a variação explicada e a variação total.
- $100 \times R^2$  é a porcentagem de variação de  $y$  explicada pelo modelo.
- $R^2$  próximo de **0** indica um ajuste **ruim**,  $R^2$  próximo de **1** indica um **bom** ajuste.
- $R^2$  é o quadrado do coeficiente de correlação entre  $y$  e  $\hat{y}$ .



# Qualidade de ajuste

## Como é o ajuste em cada um dos modelos?

```
modelo1 = lm(salario~roe, data = CEOSAL1)  
cor(CEOSAL1$salario,fitted.values(modelo1))^2
```

```
## [1] 0.01318862
```

```
summary(modelo1)$r.squared
```

```
## [1] 0.01318862
```

```
modelo2 = lm(votosA~despesasA, data = VOTE1)  
summary(modelo2)$r.squared
```

```
## [1] 0.8561459
```

## Leituras recomendadas

### Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 2.2-2.3**