

# Modelos de Regressão e Previsão

## Modelo de Regressão Linear Simples

Prof. Carlos Trucíos  
carlos.trucios@facc.ufrj.br  
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis  
Universidade Federal do Rio de Janeiro

## Aula 3

# Interpretação dos coeficientes

## Unidades de medida

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,4)]  
colnames(CEOSAL1) = c("salario", "roe")  
CEOSAL1$salariodol = CEOSAL1$salario*1000  
CEOSAL1$roedec = CEOSAL1$roe/100  
head(CEOSAL1)
```

##	salario	roe	salariodol	roedec
## 1	1095	14.1	1095000	0.141
## 2	1001	10.9	1001000	0.109
## 3	1122	23.5	1122000	0.235
## 4	578	5.9	578000	0.059
## 5	1368	13.8	1368000	0.138
## 6	1145	20.0	1145000	0.200

## Unidades de medida

$\text{salariodol} = \text{salario} \times 1000$  e  $\text{roedec} = \text{roe}/100$

```
coef(lm(salario~roe, data = CEOSAL1))
```

```
## (Intercept)          roe
##   963.19133    18.50119
```

```
coef(lm(salariodol~roe, data = CEOSAL1))
```

```
## (Intercept)          roe
##  963191.33    18501.19
```

```
coef(lm(salario~roedec, data = CEOSAL1))
```

```
## (Intercept)        roedec
##   963.1913    1850.1187
```

# Unidades de medida

## Importante

Para uma correta interpretação, devemos conhecer as unidades de medida utilizadas nas variáveis dependentes e independentes.

- Se a variável dependente for  $cy$ , então os  $\hat{\beta}$ 's da regressão  $cy$  sobre  $x$  serão  $c\hat{\beta}_0$  e  $c\hat{\beta}_1$  (onde  $\hat{\beta}_0, \hat{\beta}_1$  são os betas da regressão de  $y$  sobre  $x$ ).

# Unidades de medida

## Importante

Para uma correta interpretação, devemos conhecer as unidades de medida utilizadas nas variáveis dependentes e independentes.

- Se a variável dependente for  $cy$ , então os  $\hat{\beta}$ 's da regressão  $cy$  sobre  $x$  serão  $c\hat{\beta}_0$  e  $c\hat{\beta}_1$  (onde  $\hat{\beta}_0, \hat{\beta}_1$  são os betas da regressão de  $y$  sobre  $x$ ).
- Se a variável independente for  $cx$ , então o novo coeficiente da regressão  $y$  sobre  $cx$  será  $\hat{\beta}_1/c$  ( $\hat{\beta}_0$  permanece igual).

## Unidades de medida

**O que acontece com o  $R^2$  quando mudamos a unidade de medida de algumas das variáveis?**

## Unidades de medida

**O que acontece com o  $R^2$  quando mudamos a unidade de medida de algumas das variáveis?**

```
summary(lm(salario~roe, data = CEOSAL1))$r.squared
```

```
## [1] 0.01318862
```

```
summary(lm(salariodol~roe, data = CEOSAL1))$r.squared
```

```
## [1] 0.01318862
```

```
summary(lm(salario~roedec, data = CEOSAL1))$r.squared
```

```
## [1] 0.01318862
```

Mudanças na unidade de medida não afetam o  $R^2$



## Não linearidade

Até aqui, temos enfatizado as relações lineares no nosso MLRS, porém relações lineares não são sempre fáceis de encontrar.

## Não linearidade

Até aqui, temos enfatizado as relações lineares no nosso MLRS, porém relações lineares não são sempre fáceis de encontrar.

### Transformação logarítmica

- A transformação pode linearizar a variável
- Gera um modelo com (aproximadamente) um efeito percentual constante  $\log(y) = \beta_0 + \beta_1 x + u$
- $\Delta \log(y) = \log(y_1) - \log(y_0) \approx (y_1 - y_0)/y_0 = \Delta y/y_0$ , então  $100 \times \Delta \log(y) \approx \% \Delta y$
- Logo, se  $\Delta u = 0$ , temos que

$$\% \Delta y \approx 100 \times \Delta \log(y) = (100\beta_1)\Delta x \quad (1)$$

*(para uma revisão de  $\log(\cdot)$  ver Apêndice **A.4b**)*

## Não linearidade

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,c(1,2)]  
colnames(WAGE1) = c("salario", "educacao")  
coef(lm(log(salario)~educacao, data = WAGE1))
```

```
## (Intercept)      educacao  
##  0.58377267  0.08274437
```

$$\% \Delta \text{Salario} \approx (100\beta_1)\Delta \text{educacao}$$

A cada ano adicional de educação, o salario aumenta  
( $100 \times 0.08274 = 8,274\%$ )

# Não linearidade

## Modelo de elasticidade constante

*Elasticidade* de  $y$  em relação a  $x$ : variação percentual de  $y$  quando  $x$  aumenta 1%.

$$\frac{\Delta y}{\Delta x} \frac{x_0}{y_0} = \frac{\% \Delta y}{\% \Delta x}$$

# Não linearidade

## Modelo de elasticidade constante

*Elasticidade* de  $y$  em relação a  $x$ : variação percentual de  $y$  quando  $x$  aumenta 1%.

$$\frac{\Delta y}{\Delta x} \frac{x_0}{y_0} = \frac{\% \Delta y}{\% \Delta x}$$

Se usarmos a aproximação (1), temos que:

$$\frac{\% \Delta y}{\% \Delta x} = \frac{\Delta \log(y)}{\Delta \log(x)} = \beta_1$$

# Não linearidade

## Modelo de elasticidade constante

*Elasticidade* de  $y$  em relação a  $x$ : variação percentual de  $y$  quando  $x$  aumenta 1%.

$$\frac{\Delta y}{\Delta x} \frac{x_0}{y_0} = \frac{\% \Delta y}{\% \Delta x}$$

Se usarmos a aproximação (1), temos que:

$$\frac{\% \Delta y}{\% \Delta x} = \frac{\Delta \log(y)}{\Delta \log(x)} = \beta_1$$

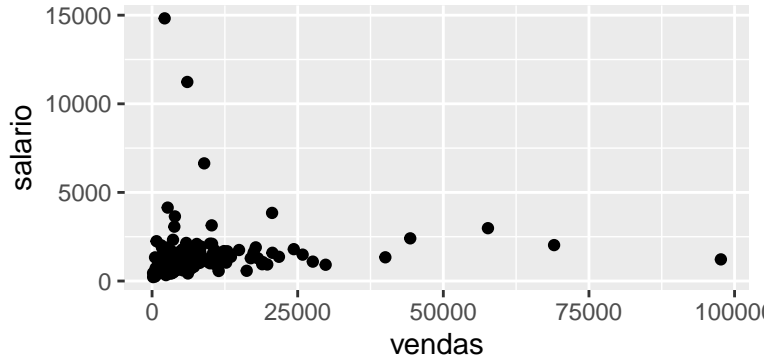
Então, na regressão

$$\log(y) = \beta_0 + \beta_1 \log(x) + u,$$


$\beta_1$  é a elasticidade de  $y$  em relação a  $x$ .

## Não linearidade

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,3)]  
colnames(CEOSAL1) = c("salario", "vendas")
```



## Não linearidade





## Não linearidade

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,3)]  
colnames(CEOSAL1) = c("salario", "vendas")  
coef(lm(log(salario)~log(vendas),data = CEOSAL1))
```

```
## (Intercept) log(vendas)  
##      4.8219965      0.2566717
```

## Não linearidade

```
CEOSAL1 = read.table("./DadosMRP/ceosal1.txt")[,c(1,3)]
colnames(CEOSAL1) = c("salario", "vendas")
coef(lm(log(salario)~log(vendas),data = CEOSAL1))
```

```
## (Intercept) log(vendas)
##    4.8219965    0.2566717
```

$$\frac{\% \Delta \text{Salario}}{\% \Delta \text{Vendas}} = \frac{\Delta \log(\text{Salario})}{\Delta \log(\text{Vendas})} = \beta_1$$

A Elasticidade do salário em relação às vendas é 0.257. Isto implica que o aumento de 1% nas vendas, aumenta o salário dos CEOs em 0.257%

# Não linearidade

Modelo	V. Ind	V. Dep	Interpretação $\beta_1$
Nível-Nível	$y$	$x$	$\Delta y = \beta_1 \Delta x$
Nível-Log	$y$	$\log(x)$	$\Delta y = (\beta_1/100)\% \Delta x$
Log-Nível	$\log(y)$	$x$	$\% \Delta y = 100 \beta_1 \Delta x$
Log-Log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

## Importante

O termo linear no modelo de regressão linear, refere-se à linearidade nos parâmetros  $\beta_0, \beta_1$

# Propriedades dos Estimadores

# Propriedades dos Estimadores: Hipóteses

## Hipótese RLS1: Linearidade nos parâmetros

No modelo populacional:  $y = \beta_0 + \beta_1 x + u$

## Propriedades dos Estimadores: Hipóteses

### Hipótese RLS1: Linearidade nos parâmetros

No modelo populacional:  $y = \beta_0 + \beta_1 x + u$

### Hipótese RLS2: Amostragem aleatória

$(x_1, y_1), \dots, (x_n, y_n)$  constituem uma amostra aleatória de tamanho  $n$  do modelo populacional do HRLS1.

## Propriedades dos Estimadores: Hipóteses

### Hipótese RLS1: Linearidade nos parâmetros

No modelo populacional:  $y = \beta_0 + \beta_1 x + u$

### Hipótese RLS2: Amostragem aleatória

$(x_1, y_1), \dots, (x_n, y_n)$  constituem uma amostra aleatória de tamanho  $n$  do modelo populacional do HRLS1.

### Hipótese RLS3: Variância amostral da variável independente

$x_1, \dots, x_n$  não são todos iguais.

## Propriedades dos Estimadores: Hipóteses

### Hipótese RLS1: Linearidade nos parâmetros

No modelo populacional:  $y = \beta_0 + \beta_1 x + u$

### Hipótese RLS2: Amostragem aleatória

$(x_1, y_1), \dots, (x_n, y_n)$  constituem uma amostra aleatória de tamanho  $n$  do modelo populacional do HRLS1.

### Hipótese RLS3: Variância amostral da variável independente

$x_1, \dots, x_n$  não são todos iguais.

### Hipótese RLS4: Média condicional zero

$$E(u|x) = 0$$



## Propriedades dos Estimadores: EMQO são não-viesados

MQO são não-viesados

Sobre HRLS1 – HRLS4,

$$E(\hat{\beta}_0) = \beta_0 \quad \text{e} \quad E(\hat{\beta}_1) = \beta_1$$

## Propriedades dos Estimadores: EMQO são não-viesados

MQO são não-viesados

Sobre HRLS1 – HRLS4,

$$E(\hat{\beta}_0) = \beta_0 \quad \text{e} \quad E(\hat{\beta}_1) = \beta_1$$

**Prova**

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) \overbrace{(\beta_0 + \beta_1 x_i + u_i)}^{y_i}}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

## Propriedades dos Estimadores: EMQO são não-viesados

MQO são não-viesados

Sobre HRLS1 – HRLS4,

$$E(\hat{\beta}_0) = \beta_0 \quad \text{e} \quad E(\hat{\beta}_1) = \beta_1$$

**Prova**

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) \overbrace{(\beta_0 + \beta_1 x_i + u_i)}^{y_i}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\beta}_1 &= \frac{\overbrace{\beta_0 \sum_{i=1}^n (x_i - \bar{x})}^0 + \beta_1 \sum_{i=1}^n (x_i - \bar{x})x_i + \overbrace{\sum_{i=1}^n (x_i - \bar{x})u_i}^0}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{aligned}$$

## Propriedades dos Estimadores: EMQO são não-viesados

(... cont) Prova

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

## Propriedades dos Estimadores: EMQO são não-viesados

(... cont) Prova

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Aplicando  $E(\cdot|x)$  em ambos os lados.

# Propriedades dos Estimadores: EMQO são não-viesados

## (...cont) Prova

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Aplicando  $E(\cdot|x)$  em ambos os lados.

$$E(\hat{\beta}_1|x) = \beta_1 + \underbrace{E\left(\frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right)}_{\sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \underbrace{E(u_i|x)}_0} = \beta_1$$

# Propriedades dos Estimadores: EMQO são não-viesados

## (...cont) Prova

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Aplicando  $E(\cdot|x)$  em ambos os lados.

$$E(\hat{\beta}_1|x) = \beta_1 + \underbrace{E\left(\frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right)}_{\sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \underbrace{E(u_i|x)}_0} = \beta_1$$

$$\underbrace{E[E(\hat{\beta}_1)|x]}_{\text{propriedade: } E(E(\cdot|x))=E(\cdot)} = E(\beta_1) = \beta_1$$

# Propriedades dos Estimadores: EMQO são não-viesados

## (... cont) Prova

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (\underbrace{\beta_0 + \beta_1 \bar{x} + \bar{u}}_{\bar{y}} - \hat{\beta}_1 \bar{x})$$



# Propriedades dos Estimadores: EMQO são não-viesados

## (... cont) Prova

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \underbrace{(\beta_0 + \beta_1 \bar{x} + \bar{u})}_{\bar{y}} - \hat{\beta}_1 \bar{x}$$

Aplicando  $E(\cdot|x)$  em ambos os lados.

$$E(\hat{\beta}_0|x) = \beta_0 + \beta_1 \underbrace{E(\bar{x}|x)}_{\bar{x}} + \underbrace{E(\bar{u}|x)}_0 - \underbrace{E(\hat{\beta}_1 \bar{x}|x)}_{\bar{x}E(\hat{\beta}_1|x)=\bar{x}\beta_1}$$

# Propriedades dos Estimadores: EMQO são não-viesados

## (... cont) Prova

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \underbrace{(\beta_0 + \beta_1 \bar{x} + \bar{u})}_{\bar{y}} - \hat{\beta}_1 \bar{x}$$

Aplicando  $E(\cdot|x)$  em ambos os lados.

$$E(\hat{\beta}_0|x) = \beta_0 + \beta_1 \underbrace{E(\bar{x}|x)}_{\bar{x}} + \underbrace{E(\bar{u}|x)}_0 - \underbrace{E(\hat{\beta}_1 \bar{x}|x)}_{\bar{x}E(\hat{\beta}_1|x)=\bar{x}\beta_1}$$

$$E[E(\hat{\beta}_0|x)] = E(\beta_0) = \beta_0$$

## Propriedades dos Estimadores: variância dos EMQO

- Já sabemos que  $E(\hat{\beta}_0) = \beta_0$  e  $E(\hat{\beta}_1) = \beta_1$ , *i.e.* a distribuição amostral de  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) está centrada em torno de  $\beta_1$  ( $\beta_0$ ).

## Propriedades dos Estimadores: variância dos EMQO

- Já sabemos que  $E(\hat{\beta}_0) = \beta_0$  e  $E(\hat{\beta}_1) = \beta_1$ , i.e. a distribuição amostral de  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) está centrada em torno de  $\beta_1$  ( $\beta_0$ ).
- Agora estamos interessados em saber o quão distante podemos esperar que  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) esteja de  $\beta_1$  ( $\beta_0$ )

## Propriedades dos Estimadores: variância dos EMQO

- Já sabemos que  $E(\hat{\beta}_0) = \beta_0$  e  $E(\hat{\beta}_1) = \beta_1$ , i.e. a distribuição amostral de  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) está centrada em torno de  $\beta_1$  ( $\beta_0$ ).
- Agora estamos interessados em saber o quão distante podemos esperar que  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) esteja de  $\beta_1$  ( $\beta_0$ )
- Em particular, queremos conhecer  $V(\hat{\beta}_0)$ ,  $V(\hat{\beta}_1)$

## Propriedades dos Estimadores: variância dos EMQO

- Já sabemos que  $E(\hat{\beta}_0) = \beta_0$  e  $E(\hat{\beta}_1) = \beta_1$ , i.e. a distribuição amostral de  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) está centrada em torno de  $\beta_1$  ( $\beta_0$ ).
- Agora estamos interessados em saber o quão distante podemos esperar que  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) esteja de  $\beta_1$  ( $\beta_0$ )
- Em particular, queremos conhecer  $V(\hat{\beta}_0)$ ,  $V(\hat{\beta}_1)$

## Propriedades dos Estimadores: variância dos EMQO

- Já sabemos que  $E(\hat{\beta}_0) = \beta_0$  e  $E(\hat{\beta}_1) = \beta_1$ , i.e. a distribuição amostral de  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) está centrada em torno de  $\beta_1$  ( $\beta_0$ ).
- Agora estamos interessados em saber o quão distante podemos esperar que  $\hat{\beta}_1$  ( $\hat{\beta}_0$ ) esteja de  $\beta_1$  ( $\beta_0$ )
- Em particular, queremos conhecer  $V(\hat{\beta}_0)$ ,  $V(\hat{\beta}_1)$

### Hipótese RLS5: Homocedasticidade

$$V(u|x) = E(u^2|x) - (E(u|x))^2 = E(u^2|x) = \sigma^2$$

## Propriedades dos Estimadores: variância dos EMQO

### Variância dos EMQO

Sobre HRLS1 – HRLS5,

$$V(\hat{\beta}_1|x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{e} \quad V(\hat{\beta}_0|x) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

onde  $\sigma^2$  é a variância do erro ( $V(u) = \sigma^2$ )

### Prova

Sabemos que 
$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$



# Propriedades dos Estimadores: variância dos EMQO

## Variância dos EMQO

Sobre HRLS1 – HRLS5,

$$V(\hat{\beta}_1|x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{e} \quad V(\hat{\beta}_0|x) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

onde  $\sigma^2$  é a variância do erro ( $V(u) = \sigma^2$ )

## Prova

Sabemos que  $\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$ .

- $V(\hat{\beta}_1|x) = V\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right) = V\left(\frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right)$

## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$V(\hat{\beta}_1|x) = V\left(\frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right) = \frac{V(\sum_{i=1}^n (x_i - \bar{x})u_i | x)}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2}$$

## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$V(\hat{\beta}_1|x) = V\left(\frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| x\right) = \frac{V(\sum_{i=1}^n (x_i - \bar{x})u_i | x)}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2}$$

Como os  $u_i$ s são independentes (HRLS2)

$$V(\hat{\beta}_1|x) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \overbrace{V(u_i|x)}^{\sigma^2}}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

## Propriedades dos Estimadores: variância dos EMQO

### (...continuação) Prova

Sabemos que,

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{e} \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

## Propriedades dos Estimadores: variância dos EMQO

### (...continuação) Prova

Sabemos que,

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{e} \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \frac{\sum_{i=1}^n y_i}{n} - \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \bar{x} = \sum_{i=1}^n \left( \frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) y_i$$

## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$V(\hat{\beta}_0|x) = \sum_{i=1}^n \left( \frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 \underbrace{V(\overbrace{\beta_0 + \beta_1 x_i + u_i}^{y_i} | x)}_{\sigma^2}$$

## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$\begin{aligned}
 V(\hat{\beta}_0|x) &= \sum_{i=1}^n \left( \frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 \underbrace{V(\overbrace{\beta_0 + \beta_1 x_i + u_i}^{y_i} | x)}_{\sigma^2} \\
 &= \sigma^2 \sum_{i=1}^n \left[ \frac{1}{n^2} + \left( \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 - 2 \frac{(x_i - \bar{x})\bar{x}}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]
 \end{aligned}$$

## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$\begin{aligned}
 V(\hat{\beta}_0|x) &= \sum_{i=1}^n \left( \frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 \underbrace{V(\overbrace{\beta_0 + \beta_1 x_i + u_i}^{y_i} | x)}_{\sigma^2} \\
 &= \sigma^2 \sum_{i=1}^n \left[ \frac{1}{n^2} + \left( \frac{(x_i - \bar{x})\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 - 2 \frac{(x_i - \bar{x})\bar{x}}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 &= \sigma^2 \left[ \frac{n}{n^2} + \sum_{i=1}^n \frac{(x_i - \bar{x})^2 \bar{x}^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \right] = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]
 \end{aligned}$$



## Propriedades dos Estimadores: variância dos EMQO

(...continuação) Prova

$$V(\hat{\beta}_0|x) = \sigma^2 \left[ \frac{\overbrace{\sum_{i=1}^n x_i^2 - n\bar{x}^2}^n}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] = \sigma^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

## Variância do erro

## Estimação da variância do erro

- Na prática, não conhecemos  $\sigma^2$
- Utilizaremos os dados para estimar  $\sigma^2$ , esse valor é denotado por  $\hat{\sigma}^2$ .

### Erros vs. Resíduo

- $u$  no modelo populacional é o erro,  $\hat{u}$  são os resíduos e aparecem na equação estimada
- Os erros ( $u$ ) são não-observáveis, já os resíduos ( $\hat{u}$ ) são calculados a partir dos dados
- $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i$

## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n} ?$

## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n}$ ?
- Nunca conhecemos  $u$

## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n}$ ?
- Nunca conhecemos  $u$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}$ ?

## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n}$ ?
- Nunca conhecemos  $u$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}$ ?
- É um estimador de  $\sigma^2$ , porém ele é viesado ( $E(\hat{\sigma}^2) \neq \sigma^2$ )

## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n}$ ?
- Nunca conhecemos  $u$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}$ ?
- É um estimador de  $\sigma^2$ , porém ele é viesado ( $E(\hat{\sigma}^2) \neq \sigma^2$ )



## Estimação da variância do erro

- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n u_i^2}{n}$ ?
- Nunca conhecemos  $u$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}$ ?
- É um estimador de  $\sigma^2$ , porém ele é viesado ( $E(\hat{\sigma}^2) \neq \sigma^2$ )

### Estimação não-viesada de $\sigma^2$

Sobre HRLS1–HRLS5,

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - 2}$$

é um estimador não-viesado para  $\sigma^2$  ( $E(\hat{\sigma}^2) = \sigma^2$ ).

## Estimação da variância do erro: Prova

Sabemos que

$$\hat{u}_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i, \quad (2)$$

então, (somando os  $n$  elementos e dividindo po  $n$ )

## Estimação da variância do erro: Prova

Sabemos que

$$\hat{u}_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i, \quad (2)$$

então, (somando os  $n$  elementos e dividindo por  $n$ )

$$\underbrace{\bar{\hat{u}}}_0 = \bar{u} - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)\bar{x}, \quad (3)$$

## Estimação da variância do erro: Prova

Sabemos que

$$\hat{u}_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i, \quad (2)$$

então, (somando os  $n$  elementos e dividindo po  $n$ )

$$\underbrace{\bar{\hat{u}}}_0 = \bar{u} - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)\bar{x}, \quad (3)$$

Fazendo (2) - (3),

$$\hat{u}_i = u_i - \bar{u} - (\hat{\beta}_1 - \beta_1)(x_i - \bar{x}), \quad (4)$$

## Estimação da variância do erro: Prova

Sabemos que

$$\hat{u}_i = u_i - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)x_i, \quad (2)$$

então, (somando os  $n$  elementos e dividindo por  $n$ )

$$\underbrace{\bar{\hat{u}}}_0 = \bar{u} - (\hat{\beta}_0 - \beta_0) - (\hat{\beta}_1 - \beta_1)\bar{x}, \quad (3)$$

Fazendo (2) - (3),

$$\hat{u}_i = u_i - \bar{u} - (\hat{\beta}_1 - \beta_1)(x_i - \bar{x}), \quad (4)$$

Logo,

$$\sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (u_i - \bar{u})^2 + (\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 - 2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n (u_i - \bar{u})(x_i - \bar{x}),$$

## Estimação da variância do erro: Prova

Como 
$$\sum_{i=1}^n (u_i - \bar{u})(x_i - \bar{x}) = \sum_{i=1}^n u_i(x_i - \bar{x})$$

## Estimação da variância do erro: Prova

Como 
$$\sum_{i=1}^n (u_i - \bar{u})(x_i - \bar{x}) = \sum_{i=1}^n u_i(x_i - \bar{x})$$

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = E\left(\sum_{i=1}^n (u_i - \bar{u})^2 + (\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 - 2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x}) | x\right)$$

## Estimação da variância do erro: Prova

$$\text{Como } \sum_{i=1}^n (u_i - \bar{u})(x_i - \bar{x}) = \sum_{i=1}^n u_i(x_i - \bar{x})$$

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = E\left(\sum_{i=1}^n (u_i - \bar{u})^2 + (\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 - 2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x}) | x\right)$$

Pela linearidade da Esperança, teremos três termos:

- **Primeiro termo:**  $E\left(\sum_{i=1}^n (u_i - \bar{u})^2 | x\right)$
- **Segundo termo:**  $E\left((\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 | x\right)$
- **Terceiro termo:**  $E\left(2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x}) | x\right)$



## Estimação da variância do erro: Prova

### Primeiro termo

$$\sum_{i=1}^n (u_i - \bar{u})^2 = \sum_{i=1}^n (u_i^2 + \bar{u}^2 - 2u_i\bar{u}) = \sum_{i=1}^n u_i^2 + n\bar{u}^2 - 2\bar{u} \underbrace{\sum_{i=1}^n u_i}_{n\bar{u}} = \sum_{i=1}^n u_i^2 - n\bar{u}^2$$

## Estimação da variância do erro: Prova

### Primeiro termo

$$\sum_{i=1}^n (u_i - \bar{u})^2 = \sum_{i=1}^n (u_i^2 + \bar{u}^2 - 2u_i\bar{u}) = \sum_{i=1}^n u_i^2 + n\bar{u} - 2\bar{u} \underbrace{\sum_{i=1}^n u_i}_{n\bar{u}} = \sum_{i=1}^n u_i^2 - n\bar{u}^2$$

Aplicando  $E(\cdot|x)$  em ambos os lados

$$E\left[\sum_{i=1}^n (u_i - \bar{u})^2 | x\right] = E\left[\sum_{i=1}^n u_i^2 | x\right] - nE[\bar{u}^2] = \underbrace{\sum_{i=1}^n E(u_i^2 | x)}_{n\sigma^2} - n \underbrace{E[\bar{u}^2]}_{\frac{\sigma^2}{n}} = (n-1)\sigma^2$$

# Estimação da variância do erro: Prova

## Segundo termo

$$E((\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 | x) = \sum_{i=1}^n (x_i - \bar{x})^2 \underbrace{E((\hat{\beta}_1 - \beta_1)^2 | x)}_{\sigma^2}$$

$$V(\hat{\beta}_1 | x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$E((\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2 | x) = \sum_{i=1}^n (x_i - \bar{x})^2 \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sigma^2$$

## Estimação da variância do erro: Prova

### Terceiro termo

Lembremos que  $\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n u_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$ , então

$$(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n u_i(x_i - \bar{x})$$

## Estimação da variância do erro: Prova

### Terceiro termo

Lembremos que  $\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n u_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$ , então

$$(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n u_i(x_i - \bar{x})$$

Logo,  $2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x}) = 2(\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2$

## Estimação da variância do erro: Prova

### Terceiro termo

Lembremos que  $\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n u_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$ , então

$$(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n u_i(x_i - \bar{x})$$

Logo,  $2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x}) = 2(\hat{\beta}_1 - \beta_1)^2 \sum_{i=1}^n (x_i - \bar{x})^2$

Aplicando  $E(\cdot|x)$  em ambos os lados,

$$\begin{aligned} \frac{E[2(\hat{\beta}_1 - \beta_1) \sum_{i=1}^n u_i(x_i - \bar{x})|x]}{2 \sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{E[(\hat{\beta}_1 - \beta_1)^2|x]}{\sigma^2} = 2\sigma^2 \\ V(\hat{\beta}_1|x) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{aligned}$$

## Estimação da variância do erro: Prova

Juntamente os resultados do **primeiro**, **segundo** e **terceiro** termo,

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = (n-1)\sigma^2 + \sigma^2 - 2\sigma^2 = (n-2)\sigma^2$$

## Estimação da variância do erro: Prova

Juntamente os resultados do **primeiro**, **segundo** e **terceiro** termo,

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = (n-1)\sigma^2 + \sigma^2 - 2\sigma^2 = (n-2)\sigma^2$$

Como  $E(E(\cdot | x)) = E(\cdot)$ ,



## Estimação da variância do erro: Prova

Juntamente os resultados do **primeiro**, **segundo** e **terceiro** termo,

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = (n-1)\sigma^2 + \sigma^2 - 2\sigma^2 = (n-2)\sigma^2$$

Como  $E(E(\cdot | x)) = E(\cdot)$ ,

$$E\left[E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right)\right] = E\left(\sum_{i=1}^n \hat{u}_i^2\right) = (n-2)\sigma^2$$

## Estimação da variância do erro: Prova

Juntamente os resultados do **primeiro**, **segundo** e **terceiro** termo,

$$E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right) = (n-1)\sigma^2 + \sigma^2 - 2\sigma^2 = (n-2)\sigma^2$$

Como  $E(E(\cdot | x)) = E(\cdot)$ ,

$$E\left[E\left(\sum_{i=1}^n \hat{u}_i^2 | x\right)\right] = E\left(\sum_{i=1}^n \hat{u}_i^2\right) = (n-2)\sigma^2$$

$$\text{Logo, } E\left(\frac{\sum_{i=1}^n \hat{u}_i^2}{n-2}\right) = \sigma^2$$

## Leituras recomendadas

### Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 2.4-2.6**