

# Modelos de Regressão e Previsão

## Análise de Regressão Linear Multipla: Inferência

Prof. Carlos Trucíos  
carlos.trucios@facc.ufrj.br  
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis  
Universidade Federal do Rio de Janeiro

## Aula 6

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que  $u$  é *normalmente distribuido*

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que  $u$  é *normalmente distribuido*

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que  $u$  é *normalmente distribuido*

## HRLM6: Normalidade

O erro populacional  $u$  é independente das variáveis explicativas ( $X$ ) e  
 $u \sim N(0, \sigma^2)$

# Introdução

- Até agora conhecemos  $E(\hat{\beta})$  e  $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que  $u$  é *normalmente distribuido*

## HRLM6: Normalidade

O erro populacional  $u$  é independente das variáveis explicativas ( $X$ ) e  $u \sim N(0, \sigma^2)$

*MRLM1 – HRLM6 são conhecidas como **hipóteses do modelo linear clássico***

## Teste t



## Teste t

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
coef(modelo)
```

```
## (Intercept)          educ          exper          tenure
## 0.284359545 0.092028987 0.004121109 0.022067218
```

## Teste t

### Distribuição amostral de $\hat{\beta}_j$

Sob HRLM1–HRLM6 e condicional aos valores amostrais de  $X$ ,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j|X)}} \sim N(0, 1)$$

## Teste t

### Distribuição amostral de $\hat{\beta}_j$

Sob HRLM1–HRLM6 e condicional aos valores amostrais de  $X$ ,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j|X)}} \sim N(0, 1)$$

mas nunca conhecemos  $\sigma^2$ , então

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{V}(\hat{\beta}_j|X)}} \sim t_{n-(k+1)}$$

## Teste t

No modelo

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$$

Geralmente, estamos interessados em testar coisas do tipo

$$H_0 : \beta_j = b \quad \text{vs} \quad H_1 : \beta_j \neq b$$

$$H_0 : \beta_j \leq b \quad \text{vs} \quad H_1 : \beta_j > b$$

$$H_0 : \beta_j \geq b \quad \text{vs} \quad H_1 : \beta_j < b$$

Usualmente  $b = 0$  (mas outros valores também são utilizados)

## Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:

- $H_0 : \beta_j = b$  vs  $H_1 : \beta_j \neq b$ , **rejeitamos  $H_0$**  se  $|t_{\hat{\beta}_j}| > c_0$

## Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

**Quando:**

- $H_0 : \beta_j = b$  vs  $H_1 : \beta_j \neq b$ , **rejeitamos**  $H_0$  se  $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$  vs  $H_1 : \beta_j < b$ , **rejeitamos**  $H_0$  se  $t_{\hat{\beta}_j} < c_1$

## Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

**Quando:**

- $H_0 : \beta_j = b$  vs  $H_1 : \beta_j \neq b$ , **rejeitamos**  $H_0$  se  $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$  vs  $H_1 : \beta_j < b$ , **rejeitamos**  $H_0$  se  $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$  vs  $H_1 : \beta_j > b$ , **rejeitamos**  $H_0$  se  $t_{\hat{\beta}_j} > c_2$

## Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

**Quando:**

- $H_0 : \beta_j = b$  vs  $H_1 : \beta_j \neq b$ , **rejeitamos  $H_0$**  se  $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$  vs  $H_1 : \beta_j < b$ , **rejeitamos  $H_0$**  se  $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$  vs  $H_1 : \beta_j > b$ , **rejeitamos  $H_0$**  se  $t_{\hat{\beta}_j} > c_2$



## Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**


$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

**Quando:**


- $H_0 : \beta_j = b$  vs  $H_1 : \beta_j \neq b$ , **rejeitamos**  $H_0$  se  $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$  vs  $H_1 : \beta_j < b$ , **rejeitamos**  $H_0$  se  $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$  vs  $H_1 : \beta_j > b$ , **rejeitamos**  $H_0$  se  $t_{\hat{\beta}_j} > c_2$

onde  $c$  é obtido da distribuição  $t$  e depende do nível de significância.


## Teste t: Bilateral $H_1 : \beta_j \neq 0$



## Teste t: Unilateral $H_1 : \beta_j < 0$



## Teste t: Unilateral $H_1 : \beta_j > 0$



## Teste t

- O valor  $c$  é obtido do quantil da distribuição  $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

## Teste t

- O valor  $c$  é obtido do quantil da distribuição  $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese  
 $H_0 : \beta_j = 0$  vs  $H_1 : \beta_j \neq 0$ , e fornecem os  $p$ -valores.

## Teste t

- O valor  $c$  é obtido do quantil da distribuição  $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese  $H_0 : \beta_j = 0$  vs  $H_1 : \beta_j \neq 0$ , e fornecem os  $p$ -valores.
- Olhando para os  $p$ -valores podemos rejeitar ou não  $H_0$  sem precisar calcular  $c$

## Teste t

- O valor  $c$  é obtido do quantil da distribuição  $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese  $H_0 : \beta_j = 0$  vs  $H_1 : \beta_j \neq 0$ , e fornecem os  $p$ -valores.
- Olhando para os  $p$ -valores podemos rejeitar ou não  $H_0$  sem precisar calcular  $c$
- **Cuidado**, se nosso interesse é testar  $H_0 : \beta_j = b$  (com  $b \neq 0$ ) precisaremos fazer as contas *manualmente*



# Teste t

- O *p-valor* é a probabilidade (sob  $H_0$ ) de obter um valor tão extremo quanto aquele observado.

# Teste t

- O *p-valor* é a probabilidade (sob  $H_0$ ) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra  $H_0$ , pois indicam que o resultado dos dados ocorre com pequena probabilidade se  $H_0$  for verdadeira.

# Teste t

- O *p-valor* é a probabilidade (sob  $H_0$ ) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra  $H_0$ , pois indicam que o resultado dos dados ocorre com pequena probabilidade se  $H_0$  for verdadeira.
- O *p-valor* fornece o menor nível de significância no qual  $H_0$  deve ser rejeitada.

# Teste t

- O *p-valor* é a probabilidade (sob  $H_0$ ) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra  $H_0$ , pois indicam que o resultado dos dados ocorre com pequena probabilidade se  $H_0$  for verdadeira.
- O *p-valor* fornece o menor nível de significância no qual  $H_0$  deve ser rejeitada.
- Rejeitamos  $H_0$  se  $P - \text{valor} < p_0$

## Teste t

### P-valor

$$P - valor = P(|T| > |t_0| | H_0) = P_{H_0}(|T| > |t_0|)$$

$$P - valor = P(T < t_0 | H_0) = P_{H_0}(T < t_0)$$

$$P - valor = P(T > t_0 | H_0) = P_{H_0}(T > t_0)$$

- Uma prática comum é rejeitar  $H_0$  se  $P - valor < 0.05$

## Teste t

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
round(summary(modelo)$coefficients,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000
## exper	0.0041	0.0017	2.3914	0.0171
## tenure	0.0221	0.0031	7.1331	0.0000

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} \geq 0$  vs  $\beta_{educ} < 0$ ?

```
round(summary(modelo)$coefficients,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000
## exper	0.0041	0.0017	2.3914	0.0171
## tenure	0.0221	0.0031	7.1331	0.0000

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} \geq 0$  vs  $\beta_{educ} < 0$ ?

```
round(summary(modelo)$coefficients,4)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	0.2844	0.1042	2.7292	0.0066
##	educ	0.0920	0.0073	12.5552	0.0000
##	exper	0.0041	0.0017	2.3914	0.0171
##	tenure	0.0221	0.0031	7.1331	0.0000

- Não podemos utilizar  $P(> |t|)$  (Por quê?)



## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} \geq 0$  vs  $\beta_{educ} < 0$ ?

```
round(summary(modelo)$coefficients,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000
## exper	0.0041	0.0017	2.3914	0.0171
## tenure	0.0221	0.0031	7.1331	0.0000

- **Não podemos utilizar**  $P(> |t|)$  (Por quê?)
- Note que  $P_{H_0}(|T| > |t|) = 2P_{H_0}(T > |t|) = 2P_{H_0}(T < -|t|)$

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} \geq 0$  vs  $\beta_{educ} < 0$ ?

```
round(summary(modelo)$coefficients,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000
## exper	0.0041	0.0017	2.3914	0.0171
## tenure	0.0221	0.0031	7.1331	0.0000

- **Não podemos utilizar**  $P(> |t|)$  (Por quê?)
- Note que  $P_{H_0}(|T| > |t|) = 2P_{H_0}(T > |t|) = 2P_{H_0}(T < -|t|)$
- Então: P-valor unilateral =  $P_{H_0}(|T| > |t|)/2$

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} = 1$  vs  $\beta_{educ} \neq 1$ ?

```
round(summary(modelo)$coefficients[1:2,],4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} = 1$  vs  $\beta_{educ} \neq 1$ ?

```
round(summary(modelo)$coefficients[1:2,],4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000

- Não podemos utilizar nem “t value” nem  $P(> |t|)$  (Por quê?)

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} = 1$  vs  $\beta_{educ} \neq 1$ ?

```
round(summary(modelo)$coefficients[1:2,],4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000

- Não podemos utilizar nem “t value” nem  $P(> |t|)$  (Por quê?)
- $$t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\widehat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$$

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} = 1$  vs  $\beta_{educ} \neq 1$ ?

```
round(summary(modelo)$coefficients[1:2,],4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000

- **Não podemos utilizar nem “t value” nem  $P(> |t|)$  (Por quê?)**
- $t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\widehat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$
- $c = qt(0.025, nrow(WAGE1) - (3 + 1)) = -1.964519$

## Teste t

- E se quisermos testar  $H_0 : \beta_{educ} = 1$  vs  $\beta_{educ} \neq 1$ ?

```
round(summary(modelo)$coefficients[1:2,],4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	0.2844	0.1042	2.7292	0.0066
## educ	0.0920	0.0073	12.5552	0.0000

- Não podemos utilizar nem “t value” nem  $P(> |t|)$  (Por quê?)**
- $t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\hat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$
- $c = qt(0.025, nrow(WAGE1) - (3 + 1)) = -1.964519$
- Bilateral ( $|t_{\hat{\beta}_{educ}}| > c$ ):  $|-124.3836| > 1.964519$ , então rejeitamos  $H_0$  a um nível de significancia de 5%.

## Teste F



## Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.

## Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

## Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada  $\beta$ ?

## Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada  $\beta$ ?
- Precisamos fazer o teste de forma conjunta!

## Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada  $\beta$ ?
- Precisamos fazer o teste de forma conjunta!
- O teste F nos permite testar  $H_0$  de forma conjunta!

## Teste F

Seja o modelo **irrestrito**

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

E seja  $H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_q = 0$ . Então, o modelo **restrito** (sob  $H_0$ ) é dado por

$$y = \beta_0 + \beta_{q+1} x_{q+1} + \beta_{q+2} x_{q+2} + \dots + \beta_k x_k + u$$

### Teste F

Sob HRLM1–HRLM6, o **teste F** é dado por

$$F = \frac{(SQR_r - SQR_i)/q}{SQR_i/(n - (k + 1))} \stackrel{H_0}{\sim} F_{q, n-(k+1)}$$

# Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.

## Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos  $H_0$



## Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos  $H_0$
- Isto implica que se  $F$  for suficientemente grande, rejeitamos  $H_0$

## Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos  $H_0$
- Isto implica que se  $F$  for suficientemente grande, rejeitamos  $H_0$
- Quão grande? depende do nível de significância

## Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos  $H_0$
- Isto implica que se  $F$  for suficientemente grande, rejeitamos  $H_0$
- Quão grande? depende do nível de significância


## Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos  $H_0$
- Isto implica que se  $F$  for suficientemente grande, rejeitamos  $H_0$
- Quão grande? depende do nível de significância

```
qf(p = c(0.9, 0.95, 0.99), df1 = 5, df2 = 120)
```

```
## [1] 1.895875 2.289851 3.173545
```

# Teste F



## Teste F

No modelo  $y = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$

Queremos testar:  $H_0 : \beta_1 = 0, \beta_3 = 0$  vs  $H_1 : H_0$  não é verdadeira

$$F = \frac{(SQR_r - SQR_i)/q}{SQR_i/(n - (k + 1))} \stackrel{H_0}{\sim} F_{q, n-(k+1)}$$

```
modeloi = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
modelor = lm(log(wage) ~ exper, data = WAGE1)
SQRi = sum(residuals(modeloi)^2)
SQRr = sum(residuals(modelor)^2)
n = nrow(WAGE1); k = 3; q = 2
```

## Teste F

```
F = ((SQRr-SQRi)/SQRi)*((n-k-1)/q)  
F
```

```
## [1] 115.8532
```

```
qf(p = c(0.90, 0.95, 0.99), df1 = q, df2 = n-k-1)
```

```
## [1] 2.312772 3.012991 4.646038
```

$F > c$ , então rejeitamos  $H_0$

## Teste F

```
anova(modelor, modeloi)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Model 1: log(wage) ~ exper
```

```
## Model 2: log(wage) ~ educ + exper + tenure
```

```
##   Res.Df    RSS Df Sum of Sq      F    Pr(>F)
```

```
## 1      524 146.49
```

```
## 2      522 101.46  2    45.034 115.85 < 2.2e-16 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



## Teste F (significância geral do modelo)

Dado um modelo da forma

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u \quad (1)$$

um teste bastante rotineiro nos modelos de regressão é:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_k = 0 \quad \text{vs} \quad H_0 : H_1 \text{ não é verdadeiro}$$

Neste teste, (1) é o modelo irrestrito e (2) é o modelo restrito.

$$y = \beta_0 + u \quad (2)$$

## Teste F (significância geral do modelo)

No modelo

$$y = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$$

Queremos testar:  $H_0 : \beta_1 = 0, \beta_2 = 0, \beta_3 = 0$

```
modeloi = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
modelor = lm(log(wage) ~ 1, data = WAGE1)
SQRi = sum(residuals(modeloi)^2)
SQRr = sum(residuals(modelor)^2)
n = nrow(WAGE1); k = 3; q = 3
((SQRr-SQRi)/SQRi)*((n-k-1)/q)
```

```
## [1] 80.39092
```

## Teste F (significância geral do modelo)

```
summary(modeloi)$fstatistic
```

```
##      value      numdf      dendif  
## 80.39092    3.00000 522.00000
```

```
qf(p = c(0.9, 0.95, 0.99), df1 = 3, df2 = 522)
```

```
## [1] 2.094309 2.621981 3.819327
```

# Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição

# Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição
- Às vezes os resultados obtidos pelos testes **t** e **F** podem levar a conclusões diferentes, nestes casos é preciso analisar cuidadosamente cada caso.

## Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição
- Às vezes os resultados obtidos pelos testes **t** e **F** podem levar a conclusões diferentes, nestes casos é preciso analisar cuidadosamente cada caso.
- No **teste F** quando  $q = 1$ , o **teste F** e o **teste t** são equivalentes.

## Testes mais gerais

## Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$  vs  $H_1 : \beta_1 \neq \beta_2$



## Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$  vs  $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$  vs  $H_1 : H_0$  não é verdadeira

## Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$  vs  $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$  vs  $H_1 : H_0$  não é verdadeira

## Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$  vs  $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$  vs  $H_1 : H_0$  não é verdadeira

Não podemos usar diretamente as estatísticas de teste nem p-valores reportados por padrão, precisaremos fazê-lo *manualmente*.

## Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

## Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

$$H_0 : \beta_{jc} = \beta_{univ} \quad \text{vs} \quad H_1 : \beta_{jc} \neq \beta_{univ}$$

## Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

$$H_0 : \beta_{jc} = \beta_{univ} \quad \text{vs} \quad H_1 : \beta_{jc} \neq \beta_{univ}$$

$$H_0 : \beta_{jc} - \beta_{univ} = 0 \quad \text{vs} \quad H_1 : \beta_{jc} - \beta_{univ} \neq 0$$

## Testes mais gerais

$$\frac{\hat{\beta}_{jc} - \hat{\beta}_{univ}}{\sqrt{\widehat{V}(\hat{\beta}_{jc} - \hat{\beta}_{univ})}} = \frac{\hat{\beta}_{jc} - \hat{\beta}_{univ}}{\sqrt{\widehat{V}(\hat{\beta}_{jc}) + \widehat{V}(\hat{\beta}_{univ}) - 2\widehat{Cov}(\hat{\beta}_{jc}, \hat{\beta}_{univ})}}$$

```
summary(modelo)$coefficients
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	1.472325551	0.0210602392	69.910201	0.000000e+00
##	exper	0.004944224	0.0001574735	31.397175	4.122707e-202
##	jc	0.066696724	0.0068287941	9.766984	2.193040e-22
##	univ	0.076876252	0.0023087290	33.298084	2.955100e-225

## Testes mais gerais

```
coef(modelo)
```

```
## (Intercept)          exper          jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

```
betajc = coef(modelo)[3]; betauniv = coef(modelo)[4]
vcov(modelo)
```

```
##          (Intercept)          exper          jc
## (Intercept) 4.435337e-04 -3.104756e-06 -1.741432e-05 -1.573472e-05
## exper      -3.104756e-06  2.479792e-08 -1.718296e-08  3.933491e-08
## jc         -1.741432e-05 -1.718296e-08  4.663243e-05  1.927929e-06
## univ       -1.573472e-05  3.933491e-08  1.927929e-06  5.330231e-06
```



## Testes mais gerais

```
COV = vcov(modelo)
s2jc = COV[3,3]; s2univ = COV[4,4]; covjc_univ = COV[3,4]
Testet = (betajc-betauniv)/sqrt(s2jc+s2univ-2*covjc_univ)
abs(Testet)
```

```
##          jc
## 1.467656
```

```
n = nrow(TWOYEAR); k = 4
c(qt(0.975, df = n-k-1), 1-pt(abs(Testet),df = n-k-1))
```

```
##          jc
## 1.96031508 0.07112206
```

## Testes mais gerais

```
COV = vcov(modelo)
s2jc = COV[3,3]; s2univ = COV[4,4]; covjc_univ = COV[3,4]
Testet = (betajc-betauniv)/sqrt(s2jc+s2univ-2*covjc_univ)
abs(Testet)
```

```
##          jc
## 1.467656
```

```
n = nrow(TWOYEAR); k = 4
c(qt(0.975, df = n-k-1), 1- pt(abs(Testet),df = n-k-1))
```

```
##          jc
## 1.96031508 0.07112206
```

Não rejeitamos  $H_0$  (com um nível de significância de 5%)

## Intervalos de Confiança

## Intervalos de Confiança

Sabemos que  $\frac{\hat{\beta}_j - \beta_j}{\sqrt{\widehat{V}(\hat{\beta}_j)}} \sim t_{n-k-1}$

Então, sob HMRLM1 – HMRLM6, calcular IC para os  $\beta_j$  é simples.

### IC para $\beta_j$

Um intervalo de confiança  $(1-\alpha)\%$  para  $\beta_j$ , é dado por

$$\underbrace{\left( \hat{\beta}_j - t_{1-\alpha/2} \sqrt{\widehat{V}(\hat{\beta}_j)} \right)}_{\underline{\beta}_j} ; \underbrace{\left( \hat{\beta}_j + t_{1-\alpha/2} \sqrt{\widehat{V}(\hat{\beta}_j)} \right)}_{\bar{\beta}_j} \quad (3)$$

onde  $t_{1-\alpha/2} = F_{t_{n-k-1}}^{-1}(1 - \alpha/2)$

## Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de  $\beta_j$  estará dentro de  $(\underline{\beta}_j; \overline{\beta}_j)$  em  $(1-\alpha)100\%$  das vezes.

## Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de  $\beta_j$  estará dentro de  $(\underline{\beta}_j; \overline{\beta}_j)$  em  $(1-\alpha)100\%$  das vezes.
- Na prática, esperamos ter obtido uma a.a. que seja umas das  $(1-\alpha)100\%$  em que  $\beta_j$  estará dentro de  $(\underline{\beta}_j; \overline{\beta}_j)$ , mas não temos essa certeza.

## Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de  $\beta_j$  estará dentro de  $(\underline{\beta}_j; \overline{\beta}_j)$  em  $(1-\alpha)100\%$  das vezes.
- Na prática, esperamos ter obtido uma a.a. que seja umas das  $(1-\alpha)100\%$  em que  $\beta_j$  estará dentro de  $(\underline{\beta}_j; \overline{\beta}_j)$ , mas não temos essa certeza.
- Lembre-se, quando  $n - k - 1$  for grande, podemos aproximar a distribuição t com uma distribuição Normal

## Intervalos de Confiança

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
confint(modelo, level = 0.95)
```

##		2.5 %	97.5 %
##	(Intercept)	0.0796755739	0.48904352
##	educ	0.0776292142	0.10642876
##	exper	0.0007356984	0.00750652
##	tenure	0.0159896851	0.02814475



## MQO assíntotico

## MQO assíntotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança

## MQO assíntotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando  $u$  não é normalmente distribuído, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F

## MQO assimpotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando  $u$  não é normalmente distribuido, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F
- Felizmente, em amostras grandes ( $n \rightarrow \infty$ ), mesmo quando HRLM6 não acontece, temos que **estatística t/F** tem aproximadamente distribuição t/F.

## MQO assimpotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando  $u$  não é normalmente distribuido, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F
- Felizmente, em amostras grandes ( $n \rightarrow \infty$ ), mesmo quando HRLM6 não acontece, temos que **estatística t/F** tem aproximadamente distribuição t/F.
- Além disso, veremos algumas propriedades interessantes quando  $n \rightarrow \infty$

## MQO assimpotico

### Consistencia

Sob HRLM1–HRLM4,

$$\lim_{n \rightarrow \infty} \hat{\beta}_j = \beta_j \quad j = 1, \dots, k \quad (\text{em probabilidade})$$

- Na verdade, podemos susbtituir a HRLM4 por

$$HRLM4' : \quad E(u) = 0 \quad e \quad Cov(x_i, u) = 0 \quad \forall i$$

## MQO assintótico

### Consistencia

Sob HRLM1–HRLM4,

$$\lim_{n \rightarrow \infty} \hat{\beta}_j = \beta_j \quad j = 1, \dots, k \quad (\text{em probabilidade})$$

- Na verdade, podemos substituir a HRLM4 por

$$HRLM4' : \quad E(u) = 0 \quad e \quad Cov(x_i, u) = 0 \quad \forall i$$

- Se  $Cov(x_i, u) \neq 0$  para algum  $i$ , todos os estimadores MQO serão geralmente inconsistentes.

## MQO assintótico

### Normalidade assintótica

Sob HRLM1–HRML5,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{V}(\hat{\beta}_j)}} \stackrel{a}{\sim} N(0, 1)$$



## Leituras recomendadas

### Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 4** e **Cap 5**