

Modelos de Regressão e Previsão

Análise de Regressão Linear Multipla: Inferência

Prof. Carlos Trucíos
carlos.trucios@facc.ufrj.br
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis
Universidade Federal do Rio de Janeiro

Aula 6

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que u é *normalmente distribuido*

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que u é *normalmente distribuido*

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que u é *normalmente distribuido*

HRLM6: Normalidade

O erro populacional u é independente das variáveis explicativas (X) e $u \sim N(0, \sigma^2)$

Introdução

- Até agora conhecemos $E(\hat{\beta})$ e $V(\hat{\beta}|X)$
- Mas para fazer inferência estatística precisamos mais do que apenas conhecer os dois primeiros momentos, precisamos conhecer a distribuição amostral toda
- Vamos assumir que u é *normalmente distribuido*

HRLM6: Normalidade

O erro populacional u é independente das variáveis explicativas (X) e $u \sim N(0, \sigma^2)$

*MRLM1 – HRLM6 são conhecidas como **hipóteses do modelo linear clássico***

Teste t

Teste t

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
coef(modelo)
```

```
## (Intercept)          educ          exper          tenure
## 0.284359545 0.092028987 0.004121109 0.022067218
```

Teste t

Distribuição amostral de $\hat{\beta}_j$

Sob HRLM1–HRLM6 e condicional aos valores amostrais de X ,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j|X)}} \sim N(0, 1)$$

Teste t

Distribuição amostral de $\hat{\beta}_j$

Sob HRLM1–HRLM6 e condicional aos valores amostrais de X ,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j|X)}} \sim N(0, 1)$$

mas nunca conhecemos σ^2 , então

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{V}(\hat{\beta}_j|X)}} \sim t_{n-(k+1)}$$

Teste t

No modelo

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$$

Geralmente, estamos interessados em testar coisas do tipo

$$H_0 : \beta_j = b \quad \text{vs} \quad H_1 : \beta_j \neq b$$

$$H_0 : \beta_j \leq b \quad \text{vs} \quad H_1 : \beta_j > b$$

$$H_0 : \beta_j \geq b \quad \text{vs} \quad H_1 : \beta_j < b$$

Usualmente $b = 0$ (mas outros valores também são utilizados)

Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:

- $H_0 : \beta_j = b$ vs $H_1 : \beta_j \neq b$, **rejeitamos** H_0 se $|t_{\hat{\beta}_j}| > c_0$

Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:

- $H_0 : \beta_j = b$ vs $H_1 : \beta_j \neq b$, **rejeitamos H_0** se $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$ vs $H_1 : \beta_j < b$, **rejeitamos H_0** se $t_{\hat{\beta}_j} < c_1$

Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:

- $H_0 : \beta_j = b$ vs $H_1 : \beta_j \neq b$, **rejeitamos H_0** se $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$ vs $H_1 : \beta_j < b$, **rejeitamos H_0** se $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$ vs $H_1 : \beta_j > b$, **rejeitamos H_0** se $t_{\hat{\beta}_j} > c_2$

Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**

$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:

- $H_0 : \beta_j = b$ vs $H_1 : \beta_j \neq b$, **rejeitamos H_0** se $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$ vs $H_1 : \beta_j < b$, **rejeitamos H_0** se $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$ vs $H_1 : \beta_j > b$, **rejeitamos H_0** se $t_{\hat{\beta}_j} > c_2$

Teste t

Para testar hipóteses é preciso uma **estatística de teste**. A estatística que usaremos é chamada de **estatística t**


$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - b}{\sqrt{\widehat{V}(\hat{\beta}_j|X)}} \stackrel{H_0}{\sim} t_{n-(k+1)}$$

Quando:


- $H_0 : \beta_j = b$ vs $H_1 : \beta_j \neq b$, **rejeitamos** H_0 se $|t_{\hat{\beta}_j}| > c_0$
- $H_0 : \beta_j \geq b$ vs $H_1 : \beta_j < b$, **rejeitamos** H_0 se $t_{\hat{\beta}_j} < c_1$
- $H_0 : \beta_j \leq b$ vs $H_1 : \beta_j > b$, **rejeitamos** H_0 se $t_{\hat{\beta}_j} > c_2$

onde c é obtido da distribuição t e depende do nível de significância.


Teste t: Bilateral $H_1 : \beta_j \neq 0$



Teste t: Unilateral $H_1 : \beta_j < 0$



Teste t: Unilateral $H_1 : \beta_j > 0$



Teste t

- O valor c é obtido do quantil da distribuição $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

Teste t

- O valor c é obtido do quantil da distribuição $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese
 $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$, e fornecem os p -valores.

Teste t

- O valor c é obtido do quantil da distribuição $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$, e fornecem os p -valores.
- Olhando para os p -valores podemos rejeitar ou não H_0 sem precisar calcular c

Teste t

- O valor c é obtido do quantil da distribuição $t_{n-(k+1)}$

```
n = 100; k = 5
```

```
qt(p = c(0.01, 0.025, 0.05, 0.95, 0.99), df = n-(k+1))
```

```
## [1] -2.366674 -1.985523 -1.661226 1.661226 2.366674
```

- A maioria de softwares testam a hipótese $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$, e fornecem os p -valores.
- Olhando para os p -valores podemos rejeitar ou não H_0 sem precisar calcular c
- **Cuidado**, se nosso interesse é testar $H_0 : \beta_j = b$ (com $b \neq 0$) precisaremos fazer as contas *manualmente*

Teste t

- O *p-valor* é a probabilidade (sob H_0) de obter um valor tão extremo quanto aquele observado.

Teste t

- O *p-valor* é a probabilidade (sob H_0) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra H_0 , pois indicam que o resultado dos dados ocorre com pequena probabilidade se H_0 for verdadeira.

Teste t

- O *p-valor* é a probabilidade (sob H_0) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra H_0 , pois indicam que o resultado dos dados ocorre com pequena probabilidade se H_0 for verdadeira.
- O *p-valor* fornece o menor nível de significância no qual H_0 deve ser rejeitada.

Teste t

- O *p-valor* é a probabilidade (sob H_0) de obter um valor tão extremo quanto aquele observado.
- Valores pequenos do *p-valor* são evidências contra H_0 , pois indicam que o resultado dos dados ocorre com pequena probabilidade se H_0 for verdadeira.
- O *p-valor* fornece o menor nível de significância no qual H_0 deve ser rejeitada.
- Rejeitamos H_0 se $P - \text{valor} < p_0$

Teste t

P-valor

$$P - valor = P(|T| > |t_0| | H_0) = P_{H_0}(|T| > |t_0|)$$

$$P - valor = P(T < t_0 | H_0) = P_{H_0}(T < t_0)$$

$$P - valor = P(T > t_0 | H_0) = P_{H_0}(T > t_0)$$

- Uma prática comum é rejeitar H_0 se $P - valor < 0.05$

Teste t

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
round(summary(modelo)$coefficients,4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |
| ## exper | 0.0041 | 0.0017 | 2.3914 | 0.0171 |
| ## tenure | 0.0221 | 0.0031 | 7.1331 | 0.0000 |

Teste t

- E se quisermos testar $H_0 : \beta_{educ} \geq 0$ vs $\beta_{educ} < 0$?

```
round(summary(modelo)$coefficients,4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |
| ## exper | 0.0041 | 0.0017 | 2.3914 | 0.0171 |
| ## tenure | 0.0221 | 0.0031 | 7.1331 | 0.0000 |

Teste t

- E se quisermos testar $H_0 : \beta_{educ} \geq 0$ vs $\beta_{educ} < 0$?

```
round(summary(modelo)$coefficients,4)
```

| ## | | Estimate | Std. Error | t value | Pr(> t) |
|----|-------------|----------|------------|---------|----------|
| ## | (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## | educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |
| ## | exper | 0.0041 | 0.0017 | 2.3914 | 0.0171 |
| ## | tenure | 0.0221 | 0.0031 | 7.1331 | 0.0000 |

- Não podemos utilizar $P(> |t|)$ (Por quê?)

Teste t

- E se quisermos testar $H_0 : \beta_{educ} \geq 0$ vs $\beta_{educ} < 0$?

```
round(summary(modelo)$coefficients,4)
```

| ## | | Estimate | Std. Error | t value | Pr(> t) |
|----|-------------|----------|------------|---------|----------|
| ## | (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## | educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |
| ## | exper | 0.0041 | 0.0017 | 2.3914 | 0.0171 |
| ## | tenure | 0.0221 | 0.0031 | 7.1331 | 0.0000 |

- **Não podemos utilizar** $P(> |t|)$ (Por quê?)
- Note que $P_{H_0}(|T| > |t|) = 2P_{H_0}(T > |t|) = 2P_{H_0}(T < -|t|)$

Teste t

- E se quisermos testar $H_0 : \beta_{educ} \geq 0$ vs $\beta_{educ} < 0$?

```
round(summary(modelo)$coefficients,4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |
| ## exper | 0.0041 | 0.0017 | 2.3914 | 0.0171 |
| ## tenure | 0.0221 | 0.0031 | 7.1331 | 0.0000 |

- **Não podemos utilizar** $P(> |t|)$ (Por quê?)
- Note que $P_{H_0}(|T| > |t|) = 2P_{H_0}(T > |t|) = 2P_{H_0}(T < -|t|)$
- Então: P-valor unilateral = $P_{H_0}(|T| > |t|)/2$

Teste t

- E se quisermos testar $H_0 : \beta_{educ} = 1$ vs $\beta_{educ} \neq 1$?

```
round(summary(modelo)$coefficients[1:2,],4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |

Teste t

- E se quisermos testar $H_0 : \beta_{educ} = 1$ vs $\beta_{educ} \neq 1$?

```
round(summary(modelo)$coefficients[1:2,],4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |

- Não podemos utilizar nem “t value” nem $P(> |t|)$ (Por quê?)

Teste t

- E se quisermos testar $H_0 : \beta_{educ} = 1$ vs $\beta_{educ} \neq 1$?

```
round(summary(modelo)$coefficients[1:2,],4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |

- Não podemos utilizar nem “t value” nem $P(> |t|)$ (Por quê?)
- $t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\widehat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$

Teste t

- E se quisermos testar $H_0 : \beta_{educ} = 1$ vs $\beta_{educ} \neq 1$?

```
round(summary(modelo)$coefficients[1:2,],4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |

- **Não podemos utilizar nem “t value” nem $P(> |t|)$ (Por quê?)**
- $t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\widehat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$
- $c = qt(0.025, nrow(WAGE1) - (3 + 1)) = -1.964519$

Teste t

- E se quisermos testar $H_0 : \beta_{educ} = 1$ vs $\beta_{educ} \neq 1$?

```
round(summary(modelo)$coefficients[1:2,],4)
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 0.2844 | 0.1042 | 2.7292 | 0.0066 |
| ## educ | 0.0920 | 0.0073 | 12.5552 | 0.0000 |

- **Não podemos utilizar nem “t value” nem $P(> |t|)$ (Por quê?)**
- $t_{\hat{\beta}_{educ}} = \frac{\hat{\beta}_{educ} - 1}{\sqrt{\widehat{V}(\hat{\beta}_{educ})}} = \frac{0.0920 - 1}{0.0073} = -124.3836$
- $c = qt(0.025, nrow(WAGE1) - (3 + 1)) = -1.964519$
- Bilateral ($|t_{\hat{\beta}_{educ}}| > c$): $|-124.3836| > 1.964519$, então rejeitamos H_0 a um nível de significância de 5%.

Teste F

Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.

Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada β ?

Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada β ?
- Precisamos fazer o teste de forma conjunta!

Teste F

- A **estatística t** é utilizada para testar **individualmente** os parâmetros do modelo.
- Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_8 x_8$$

e suponha que queremos testar

$$H_0 : \beta_2 = 0, \beta_3 = 0, \beta_5 = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdadeiro}$$

- Fazer um **teste t** para cada β ?
- Precisamos fazer o teste de forma conjunta!
- O teste F nos permite testar H_0 de forma conjunta!

Teste F

Seja o modelo **irrestrito**

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

E seja $H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_q = 0$. Então, o modelo **restrito** (sob H_0) é dado por

$$y = \beta_0 + \beta_{q+1} x_{q+1} + \beta_{q+2} x_{q+2} + \dots + \beta_k x_k + u$$

Teste F

Sob HRLM1–HRLM6, o **teste F** é dado por

$$F = \frac{(SQR_r - SQR_i)/q}{SQR_i/(n - (k + 1))} \stackrel{H_0}{\sim} F_{q, n-(k+1)}$$

Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.

Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos H_0

Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos H_0
- Isto implica que se F for suficientemente grande, rejeitamos H_0

Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos H_0
- Isto implica que se F for suficientemente grande, rejeitamos H_0
- Quão grande? depende do nível de significância

Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos H_0
- Isto implica que se F for suficientemente grande, rejeitamos H_0
- Quão grande? depende do nível de significância


Teste F

- Intuitivamente, estamos analisando quanto aumenta a SQR quando retiramos algumas das variáveis.
- Se o aumento no SQR for grande (em relação ao SQR do modelo completo) rejeitamos H_0
- Isto implica que se F for suficientemente grande, rejeitamos H_0
- Quão grande? depende do nível de significância

```
qf(p = c(0.9, 0.95, 0.99), df1 = 5, df2 = 120)
```

```
## [1] 1.895875 2.289851 3.173545
```

Teste F



Teste F

No modelo $y = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$

Queremos testar: $H_0 : \beta_1 = 0, \beta_3 = 0$ vs $H_1 : H_0$ não é verdadeira

$$F = \frac{(SQR_r - SQR_i)/q}{SQR_i/(n - (k + 1))} \stackrel{H_0}{\sim} F_{q, n-(k+1)}$$

```
modeloi = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
modelor = lm(log(wage) ~ exper, data = WAGE1)
SQRi = sum(residuals(modeloi)^2)
SQRr = sum(residuals(modelor)^2)
n = nrow(WAGE1); k = 3; q = 2
```

Teste F

```
F = ((SQRr-SQRi)/SQRi)*((n-k-1)/q)  
F
```

```
## [1] 115.8532
```

```
qf(p = c(0.90, 0.95, 0.99), df1 = q, df2 = n-k-1)
```

```
## [1] 2.312772 3.012991 4.646038
```

$F > c$, então rejeitamos H_0

Teste F

```
anova(modelor, modeloi)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Model 1: log(wage) ~ exper
```

```
## Model 2: log(wage) ~ educ + exper + tenure
```

```
##   Res.Df    RSS Df Sum of Sq      F    Pr(>F)
```

```
## 1      524 146.49
```

```
## 2      522 101.46  2    45.034 115.85 < 2.2e-16 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Teste F (significância geral do modelo)

Dado um modelo da forma

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u \quad (1)$$

um teste bastante rotineiro nos modelos de regressão é:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_k = 0 \quad \text{vs} \quad H_0 : H_1 \text{ não é verdadeiro}$$

Neste teste, (1) é o modelo irrestrito e (2) é o modelo restrito.

$$y = \beta_0 + u \quad (2)$$

Teste F (significância geral do modelo)

No modelo

$$y = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$$

Queremos testar: $H_0 : \beta_1 = 0, \beta_2 = 0, \beta_3 = 0$

```
modeloi = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
modelor = lm(log(wage) ~ 1, data = WAGE1)
SQRi = sum(residuals(modeloi)^2)
SQRr = sum(residuals(modelor)^2)
n = nrow(WAGE1); k = 3; q = 3
((SQRr-SQRi)/SQRi)*((n-k-1)/q)
```

```
## [1] 80.39092
```

Teste F (significância geral do modelo)

```
summary(modeloi)$fstatistic
```

```
##      value      numdf      dendif  
## 80.39092    3.00000 522.00000
```

```
qf(p = c(0.9, 0.95, 0.99), df1 = 3, df2 = 522)
```

```
## [1] 2.094309 2.621981 3.819327
```

Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição

Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição
- Às vezes os resultados obtidos pelos testes **t** e **F** podem levar a conclusões diferentes, nestes casos é preciso analisar cuidadosamente cada caso.

Teste F

- O **teste F** a diferença do **teste t**, permite que testemos conjuntamente hipóteses com mais de uma restrição
- Às vezes os resultados obtidos pelos testes **t** e **F** podem levar a conclusões diferentes, nestes casos é preciso analisar cuidadosamente cada caso.
- No **teste F** quando $q = 1$, o **teste F** e o **teste t** são equivalentes.

Testes mais gerais

Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$ vs $H_1 : \beta_1 \neq \beta_2$

Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$ vs $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$ vs $H_1 : H_0$ não é verdadeira

Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$ vs $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$ vs $H_1 : H_0$ não é verdadeira

Testes mais gerais

Seja o modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

e sejam as hipóteses

- $H_0 : \beta_1 = \beta_2$ vs $H_1 : \beta_1 \neq \beta_2$
- $H_0 : \beta_1 = 1, \beta_2 = 0, \dots, \beta_k = 0$ vs $H_1 : H_0$ não é verdadeira

Não podemos usar diretamente as estatísticas de teste nem p-valores reportados por padrão, precisaremos fazê-lo *manualmente*.

Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

$$H_0 : \beta_{jc} = \beta_{univ} \quad \text{vs} \quad H_1 : \beta_{jc} \neq \beta_{univ}$$

Testes mais gerais

```
TWOYEAR = read.table("./DadosMRP/twoyear.txt")[,8:11]
colnames(TWOYEAR) = c("exper", "jc", "univ", "lwage")
modelo = lm(lwage~., data = TWOYEAR)
coef(modelo)
```

```
## (Intercept)          exper              jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

$$H_0 : \beta_{jc} = \beta_{univ} \quad \text{vs} \quad H_1 : \beta_{jc} \neq \beta_{univ}$$

$$H_0 : \beta_{jc} - \beta_{univ} = 0 \quad \text{vs} \quad H_1 : \beta_{jc} - \beta_{univ} \neq 0$$

Testes mais gerais

$$\frac{\hat{\beta}_{jc} - \hat{\beta}_{univ}}{\sqrt{\widehat{V}(\hat{\beta}_{jc} - \hat{\beta}_{univ})}} = \frac{\hat{\beta}_{jc} - \hat{\beta}_{univ}}{\sqrt{\widehat{V}(\hat{\beta}_{jc}) + \widehat{V}(\hat{\beta}_{univ}) - 2\widehat{Cov}(\hat{\beta}_{jc}, \hat{\beta}_{univ})}}$$

```
summary(modelo)$coefficients
```

| ## | | Estimate | Std. Error | t value | Pr(> t) |
|----|-------------|-------------|--------------|-----------|---------------|
| ## | (Intercept) | 1.472325551 | 0.0210602392 | 69.910201 | 0.000000e+00 |
| ## | exper | 0.004944224 | 0.0001574735 | 31.397175 | 4.122707e-202 |
| ## | jc | 0.066696724 | 0.0068287941 | 9.766984 | 2.193040e-22 |
| ## | univ | 0.076876252 | 0.0023087290 | 33.298084 | 2.955100e-225 |

Testes mais gerais

```
coef(modelo)
```

```
## (Intercept)          exper             jc          univ
## 1.472325551 0.004944224 0.066696724 0.076876252
```

```
betajc = coef(modelo)[3]; betauniv = coef(modelo)[4]
vcov(modelo)
```

```
##              (Intercept)          exper             jc
## (Intercept)  4.435337e-04 -3.104756e-06 -1.741432e-05 -1.573472e-05
## exper       -3.104756e-06  2.479792e-08 -1.718296e-08  3.933491e-08
## jc          -1.741432e-05 -1.718296e-08  4.663243e-05  1.927929e-06
## univ        -1.573472e-05  3.933491e-08  1.927929e-06  5.330231e-07
```


Testes mais gerais

```
COV = vcov(modelo)
s2jc = COV[3,3]; s2univ = COV[4,4]; covjc_univ = COV[3,4]
Testet = (betajc-betauniv)/sqrt(s2jc+s2univ-2*covjc_univ)
abs(Testet)
```

```
##          jc
## 1.467656
```

```
n = nrow(TWOYEAR); k = 4
c(qt(0.975, df = n-k-1), 1- pt(abs(Testet),df = n-k-1))
```

```
##          jc
## 1.96031508 0.07112206
```

Testes mais gerais

```
COV = vcov(modelo)
s2jc = COV[3,3]; s2univ = COV[4,4]; covjc_univ = COV[3,4]
Testet = (betajc-betauniv)/sqrt(s2jc+s2univ-2*covjc_univ)
abs(Testet)
```

```
##          jc
## 1.467656
```

```
n = nrow(TWOYEAR); k = 4
c(qt(0.975, df = n-k-1), 1- pt(abs(Testet),df = n-k-1))
```

```
##          jc
## 1.96031508 0.07112206
```

Rejeitamos H_0 (com um nível de significância de 5%)

Intervalos de Confiança

Intervalos de Confiança

Sabemos que $\frac{\hat{\beta}_j - \beta_j}{\sqrt{\widehat{V}(\hat{\beta}_j)}} \sim t_{n-k-1}$

Então, sob HMRLM1 – HMRLM6, calcular IC para os β_j é simples.

IC para β_j

Um intervalo de confiança $(1-\alpha)\%$ para β_j , é dado por

$$\underbrace{\left(\hat{\beta}_j - t_{1-\alpha/2} \sqrt{\widehat{V}(\hat{\beta}_j)} \right)}_{\underline{\beta}_j} ; \underbrace{\left(\hat{\beta}_j + t_{1-\alpha/2} \sqrt{\widehat{V}(\hat{\beta}_j)} \right)}_{\bar{\beta}_j} \quad (3)$$

onde $t_{1-\alpha/2} = F_{t_{n-k-1}}^{-1}(1 - \alpha/2)$

Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de β_j estará dentro de $(\underline{\beta}_j; \overline{\beta}_j)$ em $(1-\alpha)100\%$ das vezes.

Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de β_j estará dentro de $(\underline{\beta}_j; \overline{\beta}_j)$ em $(1-\alpha)100\%$ das vezes.
- Na prática, esperamos ter obtido uma a.a. que seja umas das $(1-\alpha)100\%$ em que β_j estará dentro de $(\underline{\beta}_j; \overline{\beta}_j)$, mas não temos essa certeza.

Intervalos de Confiança

- Se as a.a. fossem obtidas repetidas vezes, e em todas elas calcularmos o IC 95%, o valor de β_j estará dentro de $(\underline{\beta}_j; \overline{\beta}_j)$ em $(1-\alpha)100\%$ das vezes.
- Na prática, esperamos ter obtido uma a.a. que seja umas das $(1-\alpha)100\%$ em que β_j estará dentro de $(\underline{\beta}_j; \overline{\beta}_j)$, mas não temos essa certeza.
- Lembre-se, quando $n - k - 1$ for grande, podemos aproximar a distribuição t com uma distribuição Normal

Intervalos de Confiança

```
WAGE1 = read.table("./DadosMRP/wage1.txt")[,1:4]
colnames(WAGE1) = c("wage", "educ", "exper", "tenure")
modelo = lm(log(wage) ~ educ+exper+tenure, data = WAGE1)
confint(modelo, level = 0.95)
```

| ## | 2.5 % | 97.5 % |
|----------------|--------------|------------|
| ## (Intercept) | 0.0796755739 | 0.48904352 |
| ## educ | 0.0776292142 | 0.10642876 |
| ## exper | 0.0007356984 | 0.00750652 |
| ## tenure | 0.0159896851 | 0.02814475 |

MQO assimpotico

MQO assimpotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança

MQO assíntotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando u não é normalmente distribuído, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F

MQO assimpotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando u não é normalmente distribuido, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F
- Felizmente, em amostras grandes ($n \rightarrow \infty$), mesmo quando HRLM6 não acontece, temos que **estatística t/F** tem aproximadamente distribuição t/F.

MQO assimpotico

- Até aqui, temos utilizado a HMRLM6 (Normalidade) para construir os testes de hipóteses e os intervalos de confiança
- Quando u não é normalmente distribuido, a **estatística t** não tem mais uma distribuição t, e a **estatística F** não tem mais uma distribuição F
- Felizmente, em amostras grandes ($n \rightarrow \infty$), mesmo quando HRLM6 não acontece, temos que **estatística t/F** tem aproximadamente distribuição t/F.
- Além disso, veremos algumas propriedades interessantes quando $n \rightarrow \infty$

MQO assimpotico

Consistencia

Sob HRLM1–HRLM4,

$$\lim_{n \rightarrow \infty} \hat{\beta}_j = \beta_j \quad j = 1, \dots, k \quad (\text{em probabilidade})$$

- Na verdade, podemos susbtituir a HRLM4 por

$$HRLM4' : \quad E(u) = 0 \quad e \quad Cov(x_i, u) = 0 \quad \forall i$$

MQO assintótico

Consistencia

Sob HRLM1–HRLM4,

$$\lim_{n \rightarrow \infty} \hat{\beta}_j = \beta_j \quad j = 1, \dots, k \quad (\text{em probabilidade})$$

- Na verdade, podemos substituir a HRLM4 por

$$HRLM4' : \quad E(u) = 0 \quad e \quad Cov(x_i, u) = 0 \quad \forall i$$

- Se $Cov(x_i, u) \neq 0$ para algum i , todos os estimadores MQO serão geralmente inconsistentes.

MQO assintótico

Normalidade assintótica

Sob HRLM1–HRML5,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{V}(\hat{\beta}_j)}} \stackrel{a}{\sim} N(0, 1)$$

Leituras recomendadas

Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 4** e **Cap 5**