

# Modelos de Regressão e Previsão

## Análise de Regressão Linear Multipla: Tópicos adicionais

Prof. Carlos Trucíos  
carlos.trucios@facc.ufrj.br  
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis  
Universidade Federal do Rio de Janeiro

## Aula 8

# Interpretação dos parâmetros

# Interpretação dos parâmetros

Até agora, temos trabalhado com modelos da forma

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + u$$

# Interpretação dos parâmetros

Até agora, temos trabalhado com modelos da forma

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + u$$

E se nosso modelo tivesse alguma das seguintes formas?

- $y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_3 + \beta_4 x_4 + u$

# Interpretação dos parâmetros

Até agora, temos trabalhado com modelos da forma

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + u$$

E se nosso modelo tivesse alguma das seguintes formas?

- $y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_3 + \beta_4 x_4 + u$

# Interpretação dos parâmetros

Até agora, temos trabalhado com modelos da forma

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + u$$

E se nosso modelo tivesse alguma das seguintes formas?

- $y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_3 + \beta_4 x_4 + u$

Quando temos termos polinomiais, temos que ter muito cuidado na interpretação

# Interpretação dos parâmetros

## Termo Quadrático

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 \quad (1)$$

- Se estivermos unicamente interessados na mudança esperada em  $y$  dada uma mudança em  $x$ , podemos usar diretamente (1)

# Interpretação dos parâmetros

## Termo Quadrático

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 \quad (1)$$

- Se estivermos unicamente interessados na mudança esperada em  $y$  dada uma mudança em  $x$ , podemos usar diretamente (1)
- Se estivermos interessados em conhecer o efeito de  $x$  sobre  $y$  precisamos **interpretar** o modelo.



# Interpretação dos parâmetros

## Termo Quadrático

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 \quad (1)$$

- Se estivermos unicamente interessados na mudança esperada em  $y$  dada uma mudança em  $x$ , podemos usar diretamente (1)
- Se estivermos interessados em conhecer o efeito de  $x$  sobre  $y$  precisamos **interpretar** o modelo.

# Interpretação dos parâmetros

## Termo Quadrático

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 \quad (1)$$

- Se estivermos unicamente interessados na mudança esperada em  $y$  dada uma mudança em  $x$ , podemos usar diretamente (1)
- Se estivermos interessados em conhecer o efeito de  $x$  sobre  $y$  precisamos **interpretar** o modelo.

Derivando w.r.t  $x$ , temos que  $\frac{dy}{dx} = (\hat{\beta}_1 + 2\hat{\beta}_2 x)$ , então

$$\frac{\Delta y}{\Delta x} \approx (\hat{\beta}_1 + 2\hat{\beta}_2 x)$$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

- Se  $x = 0$ ,  $\frac{\Delta y}{\Delta x} \approx \hat{\beta}_1$ ,  $\hat{\beta}_1$  pode ser interpretado como a inclinação aproximada na alteração de  $x = 0$  para  $x = 1$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

- Se  $x = 0$ ,  $\frac{\Delta y}{\Delta x} \approx \hat{\beta}_1$ ,  $\hat{\beta}_1$  pode ser interpretado como a inclinação aproximada na alteração de  $x = 0$  para  $x = 1$
- Para  $x > 0$ ,  $2\hat{\beta}_2x$  deve ser considerado na interpretação

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

- Se  $x = 0$ ,  $\frac{\Delta y}{\Delta x} \approx \hat{\beta}_1$ ,  $\hat{\beta}_1$  pode ser interpretado como a inclinação aproximada na alteração de  $x = 0$  para  $x = 1$
- Para  $x > 0$ ,  $2\hat{\beta}_2x$  deve ser considerado na interpretação

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

- Se  $x = 0$ ,  $\frac{\Delta y}{\Delta x} \approx \hat{\beta}_1$ ,  $\hat{\beta}_1$  pode ser interpretado como a inclinação aproximada na alteração de  $x = 0$  para  $x = 1$
- Para  $x > 0$ ,  $2\hat{\beta}_2x$  deve ser considerado na interpretação

```
coef(lm(wage~ exper + I(exper^2), data = WAGE1))
```

```
## (Intercept)          exper      I(exper^2)  
##  3.725405733  0.298100106 -0.006129887
```

- Como varia *wage* em função de *exper*?

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:



# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:
  - Para o segundo ano:  $0.2981 - 2 \times 0.0061(1) = 0.2859$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:
  - Para o segundo ano:  $0.2981 - 2 \times 0.0061(1) = 0.2859$
  - Para o terceiro ano:  $0.2981 - 2 \times 0.0061(2) = 0.2737$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:
  - Para o segundo ano:  $0.2981 - 2 \times 0.0061(1) = 0.2859$
  - Para o terceiro ano:  $0.2981 - 2 \times 0.0061(2) = 0.2737$
  - Para o decimo ano:  $0.2981 - 2 \times 0.0061(9) = 0.1883$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:
  - Para o segundo ano:  $0.2981 - 2 \times 0.0061(1) = 0.2859$
  - Para o terceiro ano:  $0.2981 - 2 \times 0.0061(2) = 0.2737$
  - Para o decimo ano:  $0.2981 - 2 \times 0.0061(9) = 0.1883$
- Note que o **ponto de inflexão** é  $x^* = -\hat{\beta}_1/2\hat{\beta}_2$

# Interpretação dos parâmetros


## ... (continuação) Termo Quadrático

$$\Delta y \approx (0.2981 - 2 \times 0.0061x)\Delta x$$

- O primeiro ano a experiência vale 0.2981 USD por hora
- Depois do primeiro ano, o efeito de experiência começa a cair:
  - Para o segundo ano:  $0.2981 - 2 \times 0.0061(1) = 0.2859$
  - Para o terceiro ano:  $0.2981 - 2 \times 0.0061(2) = 0.2737$
  - Para o decimo ano:  $0.2981 - 2 \times 0.0061(9) = 0.1883$
- Note que o **ponto de inflexão** é  $x^* = -\hat{\beta}_1/2\hat{\beta}_2$
- No nosso caso:  $x^* = 0.2981/(2 * 0.0061) = 24.43$

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático



# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

O que significa esse 24.43 anos?

- Se na amostra, apenas uma pequena fração dos dados apresentam idade  $> 24.43$ , não devemos nos preocupar (mas. . .)

# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

O que significa esse 24.43 anos?

- Se na amostra, apenas uma pequena fração dos dados apresentam idade  $> 24.43$ , não devemos nos preocupar (mas...)

```
prop.table(table(WAGE1$exper>24.43))
```

```
##
```

```
##      FALSE      TRUE
```

```
## 0.7205323 0.2794677
```



# Interpretação dos parâmetros

## ... (continuação) Termo Quadrático

O que significa esse 24.43 anos?

- Se na amostra, apenas uma pequena fração dos dados apresentam idade  $> 24.43$ , não devemos nos preocupar (mas...)

```
prop.table(table(WAGE1$exper>24.43))
```

```
##
```

```
##      FALSE      TRUE
```

```
## 0.7205323 0.2794677
```

- É possível que o retorno de *exper* sobre *wage* seja negativo a partir de algum ponto, mas **cuidado com as variáveis omitidas!** (levam a estimadores viesados)

# Interpretação dos parâmetros

$\log(\text{price}) =$

$$\beta_0 + \beta_1 \log(\text{nox}) + \beta_2 \log(\text{dist}) + \beta_3 \text{rooms} + \beta_4 I(\text{rooms}^2) + \beta_5 \text{stratio} + u$$

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	13.38547708	0.56647307	23.629503	1.884304e-83
##	log(nox)	-0.90168178	0.11468692	-7.862115	2.340671e-14
##	log(dist)	-0.08678134	0.04328071	-2.005081	4.549288e-02
##	rooms	-0.54511291	0.16545413	-3.294647	1.055357e-03
##	I(rooms^2)	0.06226119	0.01280498	4.862265	1.556648e-06
##	stratio	-0.04759019	0.00585419	-8.129254	3.423303e-15

## Interpretação dos parâmetros

- $\hat{\beta}_{\log(nox)}$ ,  $\hat{\beta}_{\log(dist)}$  e  $\hat{\beta}_{stratio}$  são interpretados como visto nas aulas anteriores.

$$\Delta \widehat{\log(price)} \approx (-0.545 + 2 \times 0.062rooms)\Delta rooms$$

## Interpretação dos parâmetros

- $\hat{\beta}_{\log(nox)}$ ,  $\hat{\beta}_{\log(dist)}$  e  $\hat{\beta}_{stratio}$  são interpretados como visto nas aulas anteriores.
- Como interpretamos *rooms*?

$$\Delta \widehat{\log(price)} \approx (-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

## Interpretação dos parâmetros

- $\hat{\beta}_{\log(nox)}$ ,  $\hat{\beta}_{\log(dist)}$  e  $\hat{\beta}_{stratio}$  são interpretados como visto nas aulas anteriores.
- Como interpretamos *rooms*?

$$\Delta \widehat{\log(price)} \approx (-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

## Interpretação dos parâmetros

- $\hat{\beta}_{\log(nox)}$ ,  $\hat{\beta}_{\log(dist)}$  e  $\hat{\beta}_{stratio}$  são interpretados como visto nas aulas anteriores.
- Como interpretamos *rooms*?

$$\Delta \widehat{\log(price)} \approx (-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

$$\% \Delta \widehat{price} \approx 100(-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

## Interpretação dos parâmetros

- $\hat{\beta}_{\log(nox)}$ ,  $\hat{\beta}_{\log(dist)}$  e  $\hat{\beta}_{stratio}$  são interpretados como visto nas aulas anteriores.
- Como interpretamos *rooms*?

$$\Delta \widehat{\log(price)} \approx (-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

$$\% \Delta \widehat{price} \approx 100(-0.545 + 2 \times 0.062 \text{rooms}) \Delta \text{rooms}$$

$$\% \Delta \widehat{price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

# Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4rooms)\Delta rooms$$



## Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$

# Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4rooms)\Delta rooms$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$
- Um aumento em rooms de 6 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 6 = 19.9$

## Interpretação dos parâmetros

$$\% \Delta \widehat{price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$
- Um aumento em rooms de 6 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 6 = 19.9$
- Um aumento em rooms de 4 para 5 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -4.9$

## Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$
- Um aumento em rooms de 6 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 6 = 19.9$
- Um aumento em rooms de 4 para 5 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -4.9$
- Um aumento em rooms de 3 para 4 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -17.3$

## Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$
- Um aumento em rooms de 6 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 6 = 19.9$
- Um aumento em rooms de 4 para 5 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -4.9$
- Um aumento em rooms de 3 para 4 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -17.3$


## Interpretação dos parâmetros

$$\% \widehat{\Delta price} \approx (-54.5 + 12.4 \text{rooms}) \Delta \text{rooms}$$

- Um aumento em rooms de 5 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 5 = 7.5$
- Um aumento em rooms de 6 para 6 aumenta o preço em aprox  $-54.5 + 12.4 \times 6 = 19.9$
- Um aumento em rooms de 4 para 5 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -4.9$
- Um aumento em rooms de 3 para 4 diminui o preço em aprox  $-54.5 + 12.4 \times 6 = -17.3$

*Faz sentido que aumentar o número de quartos cause uma diminuição no preço?*

# Interpretação dos parâmetros



```
## [1] 4.395161
```

## Interpretação dos parâmetros

```
summary(hprice2$rooms)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   3.560   5.883   6.210   6.284   6.620   8.780
```

```
prop.table(table(hprice2$rooms<4.4))*100
```

```
##
##      FALSE      TRUE
## 99.0118577  0.9881423
```

### Moral da historia

Faça uma boa EDA (exploratory data analysis), alguns resultados contraintuitivos podem desaparecer ao entendermos melhor os dados.



## Comparação de modelos

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.
- O  $R^2$ -ajustado, penaliza o número de variáveis e fornece uma ferramenta para compararmos modelos.

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.
- O  $R^2$ -ajustado, penaliza o número de variáveis e fornece uma ferramenta para compararmos modelos.

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.
- O  $R^2$ -ajustado, penaliza o número de variáveis e fornece uma ferramenta para compararmos modelos.

## $R^2$ -ajustado

$$R_{Adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.
- O  $R^2$ -ajustado, penaliza o número de variáveis e fornece uma ferramenta para compararmos modelos.

## $R^2$ -ajustado

$$R_{Adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

- Nos permite comparar modelos não aninhados

# Comparação de modelos

- Vimos que o  $R^2$  nunca diminui quando incluímos mais variáveis independentes.
- O  $R^2$ -ajustado, penaliza o número de variáveis e fornece uma ferramenta para compararmos modelos.

## $R^2$ -ajustado

$$R_{Adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

- Nos permite comparar modelos não aninhados
- **Cuidado com comparar modelos com variável dependente diferente**

# Comparação de modelos

```
modelo1 = lm(salary~sales+roe, data = ceosal1)
modelo2 = lm(log(salary)~log(sales)+roe, data = ceosal1)
summary(modelo1)$adj.r.squared
```

```
## [1] 0.01974617
```

```
summary(modelo2)$adj.r.squared
```

```
## [1] 0.2750177
```



# Comparação de modelos

```
modelo1 = lm(salary~sales+roe, data = ceosal1)
modelo2 = lm(log(salary)~log(sales)+roe, data = ceosal1)
summary(modelo1)$adj.r.squared
```

```
## [1] 0.01974617
```

```
summary(modelo2)$adj.r.squared
```

```
## [1] 0.2750177
```

***Cuidado com comparar modelos com variável dependente diferente***

# Comparação de modelos

```
modelo1 = lm(salary~sales+roe, data = ceosal1)
modelo2 = lm(log(salary)~log(sales)+roe, data = ceosal1)
summary(modelo1)$adj.r.squared
```

```
## [1] 0.01974617
```

```
summary(modelo2)$adj.r.squared
```

```
## [1] 0.2750177
```

***Cuidado com comparar modelos com variável dependente diferente***

*$R^2$ -ajustado não pode ser utilizado quando temos diferentes formas funcionais da variável dependente*

# Comparação de modelos

Seja

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

# Comparação de modelos

Seja

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

- $\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$

# Comparação de modelos

Seja

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

- $\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$
- Uma primeira ideia seria fazer  $\hat{y} = \exp(\widehat{\log(y)})$  (mas subestima o valor esperado  $y$ )

# Comparação de modelos

Seja

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

- $\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$
- Uma primeira ideia seria fazer  $\hat{y} = \exp(\widehat{\log(y)})$  (mas subestima o valor esperado  $y$ )
- Sabemos que  $y = \underbrace{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3)}_{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3)} \exp(u)$

# Comparação de modelos

Seja

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

- $\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$
- Uma primeira ideia seria fazer  $\hat{y} = \exp(\widehat{\log(y)})$  (mas subestima o valor esperado  $y$ )
- Sabemos que  $y = \underbrace{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3)}_{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3)} \exp(u)$
- Aplicando  $E(\cdot|x)$ ,  $E(y|X) = \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3) E(\exp(u)|X)$

# Comparação de modelos

- Se  $u \sim N(0, \sigma^2)$ ,  $E(\exp(u)|X) = \exp(\sigma^2/2)$

$$\hat{y} = \exp(\hat{\sigma}^2/2) \exp(\underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3}_{\widehat{\log(y)}}) = \exp(\hat{\sigma}^2/2) \exp(\widehat{\log(y)})$$



# Comparação de modelos

- Se  $u \sim N(0, \sigma^2)$ ,  $E(\exp(u)|X) = \exp(\sigma^2/2)$

$$\hat{y} = \exp(\hat{\sigma}^2/2) \exp(\underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3}_{\widehat{\log(y)}}) = \exp(\hat{\sigma}^2/2) \exp(\widehat{\log(y)})$$

- Se não tivermos Normalidade,

$$\hat{y} = \hat{\alpha}_0 \exp(\widehat{\log(y)})$$

onde  $\hat{\alpha}_0$  é uma estimativa de  $\alpha_0 = E(\exp(u)|X)$

# Comparação de modelos

**Como estimar  $\alpha_0$ ?**

- $\hat{\alpha}_0 = n^{-1} \sum_{i=1}^n \exp(\hat{u}_i) (>1)$

## Comparar modelos

- $R^2 = [Cor(y, \hat{y})]^2$
- $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{\alpha}_0 \hat{m}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

# Comparação de modelos

## Como estimar $\alpha_0$ ?

- $\hat{\alpha}_0 = n^{-1} \sum_{i=1}^n \exp(\hat{u}_i) (>1)$
- $\hat{\alpha}_0 = \left( \sum_{i=1}^n \hat{m}_i y_i \right) / \left( \sum_{i=1}^n \hat{m}_i^2 \right)$  onde  $\hat{m}_i = \exp(\widehat{\log(y_i)})$

## Comparar modelos

- $R^2 = [Cor(y, \hat{y})]^2$
- $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{\alpha}_0 \hat{m}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

# Comparação de modelos

```
modelo1 = lm(salary~sales+roe, data = ceosal1)
modelo2 = lm(log(salary)~log(sales)+roe, data = ceosal1)
uhat = residuals(modelo2)
alpha0_1 = mean(exp(uhat))
m = exp(fitted(modelo2))
alpha0_2 = sum(ceosal1$salary*m)/sum(m^2)
y = ceosal1$salary
```

# Comparação de modelos

```
summary(modelo1)$r.squared
```

```
## [1] 0.02917169
```

```
yhat_1 = alpha0_1*m
```

```
yhat_2 = alpha0_2*m
```

```
c(cor(y, yhat_1)^2, cor(y, yhat_2)^2)
```

```
## [1] 0.04882569 0.04882569
```

```
1- sum((y-yhat_1)^2)/sum((y-mean(y))^2)
```

```
## [1] 0.04124148
```

```
1- sum((y-yhat_2)^2)/sum((y-mean(y))^2)
```

```
## [1] 0.04258757
```

## Intervalos de Confiança / Previsão

# Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$

## Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$
- O previsão de  $y$  dados os valores  $x_0$ , são obtidos como

$$\hat{y} = E(y|x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_{0,1} + \dots + \hat{\beta}_k x_{0,k}$$



## Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$
- O previsão de  $y$  dados os valores  $x_0$ , são obtidos como

$$\hat{y} = E(y|x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_{0,1} + \dots + \hat{\beta}_k x_{0,k}$$

- E se quisermos medir a incerteza desse valor previsto?

## Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$
- O previsão de  $y$  dados os valores  $x_0$ , são obtidos como

$$\hat{y} = E(y|x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_{0,1} + \dots + \hat{\beta}_k x_{0,k}$$

- E se quisermos medir a incerteza desse valor previsto?
- Vamos construir **intervalos de confiança**

## Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$
- O previsão de  $y$  dados os valores  $x_0$ , são obtidos como

$$\hat{y} = E(y|x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_{0,1} + \dots + \hat{\beta}_k x_{0,k}$$

- E se quisermos medir a incerteza desse valor previsto?
- Vamos construir **intervalos de confiança**

## Intervalos de Confiança / Previsão

- Seja  $x_0 = (x_{0,1}, x_{0,2}, \dots, x_{0,k})$  os valores observados de  $x$
- O previsão de  $y$  dados os valores  $x_0$ , são obtidos como

$$\hat{y} = E(y|x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_{0,1} + \dots + \hat{\beta}_k x_{0,k}$$

- E se quisermos medir a incerteza desse valor previsto?
- Vamos construir **intervalos de confiança**

### IC

Um IC assintótico 95% para  $E(y|x_0)$

$$\left( x_0 \hat{\beta} - 1.96 \sqrt{x_0 \hat{V}_{\hat{\beta}} x_0'} \quad ; \quad x_0 \hat{\beta} + 1.96 \sqrt{x_0 \hat{V}_{\hat{\beta}} x_0'} \right)$$

onde  $\hat{V}_{\hat{\beta}}$  é a matriz de variância-covariância de  $\hat{\beta}$

## Intervalos de Confiança / Previsão

```
modelo = lm(colgpa~ sat + hsperc + hsize + I(hsize^2),  
            data = gpa2)  
round(coef(modelo),5)
```

## (Intercept)	sat	hsperc	hsize	I(hsize^2)
## 1.49265	0.00149	-0.01386	-0.06088	0.00546

```
x0 = data.frame(sat = 1200, hsperc = 30, hsize = 5)  
yhat = predict(modelo,newdata = x0)  
V_beta = vcov(modelo)
```

## Intervalos de Confiança / Previsão

```
x= matrix(c(1,1200,30,5,25),ncol=5)
```

```
x
```

```
##      [,1] [,2] [,3] [,4] [,5]
```

```
## [1,]    1 1200   30    5   25
```

```
c(yhat - 1.96*sqrt(x%%V_beta%%t(x)),
```

```
  yhat + 1.96*sqrt(x%%V_beta%%t(x)))
```

```
## [1] 2.661115 2.739036
```

## Intervalos de Confiança / Previsão

```
x= matrix(c(1,1200,30,5,25),ncol=5)
```

```
x
```

```
##      [,1] [,2] [,3] [,4] [,5]
```

```
## [1,]      1 1200    30     5    25
```

```
c(yhat - 1.96*sqrt(x%%V_beta%%t(x)),  
  yhat + 1.96*sqrt(x%%V_beta%%t(x)))
```

```
## [1] 2.661115 2.739036
```

```
predict(modelo,newdata = x0, interval = "confidence")
```

```
##      fit      lwr      upr
```

```
## 1 2.700075 2.661104 2.739047
```

# Intervalos de Confiança / Previsão

- Um IC da média não é a mesma coisa que um IC de uma unidade em particular



## Intervalos de Confiança / Previsão

- Um IC da média não é a mesma coisa que um IC de uma unidade em particular
- IC para uma unidade em particular são conhecidos como **intervalos de previsão** e precisam incluir uma outra fonte de variação, *a variância do erro não observado*.

## Intervalos de Confiança / Previsão

- Um IC da média não é a mesma coisa que um IC de uma unidade em particular
- IC para uma unidade em particular são conhecidos como **intervalos de previsão** e precisam incluir uma outra fonte de variação, *a variância do erro não observado*.

## Intervalos de Confiança / Previsão

- Um IC da média não é a mesma coisa que um IC de uma unidade em particular
- IC para uma unidade em particular são conhecidos como **intervalos de previsão** e precisam incluir uma outra fonte de variação, *a variância do erro não observado*.

Sabemos que

$$y_{n+1} = \beta_0 + \beta_1 x_{n+1,1} + \cdots + \beta_k x_{n+1,k} + u_{n+1}$$

Então o **erro de previsão** é dado por,

$$\hat{u}_{n+1} = y_{n+1} - \hat{y}_{n+1} = x_{n+1}\beta + u_{n+1} - x_{n+1}\hat{\beta} = x_{n+1}(\beta - \hat{\beta}) + u_{n+1}$$

## Intervalos de Confiança / Previsão

$$\begin{aligned}
 V(\hat{u}_{n+1}|x_{n+1}) &= E(\hat{u}_{n+1}^2|x_{n+1}) \\
 &= E[(x_{n+1}(\beta - \hat{\beta}) + u_{n+1})^2|x_{n+1}] \\
 &= E[x_{n+1}(\beta - \hat{\beta})(\beta - \hat{\beta})'x'_{n+1} + u_{n+1}^2 + 2x_{n+1}(\beta - \hat{\beta})\hat{u}_{n+1}|x_{n+1}] \\
 &= x_{n+1}V(\hat{\beta}|x_{n+1})x'_{n+1} + \underbrace{E(u_{n+1}^2|x_{n+1})}_{\sigma^2}
 \end{aligned}
 \tag{2}$$

### IP

Um IP 95% (assumindo Normalidade) é dado por

$$\left( x_0\hat{\beta} - 1.96\sqrt{x_0\hat{V}_{\hat{\beta}}x'_0 + \hat{\sigma}^2} \quad ; \quad x_0\hat{\beta} + 1.96\sqrt{x_0\hat{V}_{\hat{\beta}}x'_0 + \hat{\sigma}^2} \right)$$

## Intervalos de Confiança / Previsão

```
sigma2 = summary(modelo)$sigma^2
x= matrix(c(1,1200,30,5,25),ncol=5)
c(yhat - 1.96*sqrt(x%%V_beta%%t(x) + sigma2),
  yhat + 1.96*sqrt(x%%V_beta%%t(x) + sigma2))

## [1] 1.602051 3.798100
```

## Intervalos de Confiança / Previsão

```
sigma2 = summary(modelo)$sigma^2  
x= matrix(c(1,1200,30,5,25),ncol=5)  
c(yhat - 1.96*sqrt(x%*%V_beta%*%t(x) + sigma2),  
  yhat + 1.96*sqrt(x%*%V_beta%*%t(x) + sigma2))
```

```
## [1] 1.602051 3.798100
```

```
predict(modelo,newdata = x0, interval = "prediction")
```

```
##          fit          lwr          upr  
## 1 2.700075 1.601749 3.798402
```

# Leituras recomendadas

## Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 6**
- Hansen, Bruce. *Econometrics*. (2020). – **Sec 7.14 e Sec 7.15**