

# Modelos de Regressão e Previsão

Análise de regressão com dados de séries temporais

Prof. Carlos Trucíos  
carlos.trucios@facc.ufrj.br  
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis  
Universidade Federal do Rio de Janeiro

## Aula 12

# Introdução

# Introdução

- Até agora estudamos o MRL em um contexto de dados de **corte transversal**
- Sob HRLM1–HRLM5, os  $\hat{\beta}$ 's são os melhores estimadores lineares não viesados e se incluirmos HRLM6, inferência estatística exata é possível
- Dados de séries temporais se diferenciam de dados de corte transversal em que eles tem uma ordenação temporal
  - Temperatura
  - PBI
  - Índice da bolsa de valores de SP
  - Inflação
  - Taxa de desemprego
  - Demanda de produtos
- Estudaremos MRL num contexto de **séries temporais**, estabeleceremos novas hipóteses e propriedades dos estimadores

# Introdução

Sejam  $y$  e  $z$  duas séries temporais

## Modelos estáticos (ME)

Um modelo estático, relaciona  $y$  e  $z$  da forma:

$$y_t = \beta_0 + \beta_1 z_t + u_t \quad t = 1, \dots, n$$

## Modelos de defasagem distribuida finita (MDDF)

No MDDF, permitimos que as variáveis afetem  $y$  com defasagens,

$$y_t = \alpha_0 + \delta_0 z_t + \delta_1 z_{t-1} + \dots + \delta_k z_{t-k} + u_t$$

No ME, a interpretação no modelo estatístico não muda, já para interpretar o MDDF precisamos tomar maiores cuidados.

## Hipóteses do modelo

# Hipóteses do modelo

No MRL com dados de **corte transversal** tínhamos:

- **HRLM1:** O modelo populacional é linear nos parâmetros,  
$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$
- **HRLM2:**  $(y_1, x_{1,1}, \dots, x_{1,k}), \dots, (y_n, x_{n,1}, \dots, x_{n,k})$  constituem uma a.a. de tamanho  $n$  do modelo populacional
- **HRLM3:** Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HRLM4:**  $E(u|X) = 0$
- **HRLM5:** Os erros tem variância constante (homocedasticidade)
- **HRLM6:** O erro populacional  $u$  é independente das variáveis explicativas ( $X$ ) e  $u \sim N(0, \sigma^2)$

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \cdots + \beta_k x_{tk} + u_t, t = 1, \dots, n$

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.



# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3**:  $E(u_t|X) = 0, t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3**:  $E(u_t|X) = 0, t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)
- **HST4**: Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2, t = 1, \dots, n$

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3**:  $E(u_t|X) = 0, t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)
- **HST4**: Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2, t = 1, \dots, n$
- **HST5**:  $Corr(u_t, u_s|X) = 0, \forall t \neq s$  (sem correlação serial)

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t$ ,  $t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3**:  $E(u_t|X) = 0$ ,  $t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)
- **HST4**: Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2$ ,  $t = 1, \dots, n$
- **HST5**:  $Corr(u_t, u_s|X) = 0$ ,  $\forall t \neq s$  (sem correlação serial)
- **HST6**: Os erros  $u_t$  são independentes de  $X$  e  $u_t \sim N(0, \sigma^2)$

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3**:  $E(u_t|X) = 0, t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)
- **HST4**: Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2, t = 1, \dots, n$
- **HST5**:  $Corr(u_t, u_s|X) = 0, \forall t \neq s$  (sem correlação serial)
- **HST6**: Os erros  $u_t$  são independentes de  $X$  e  $u_t \sim N(0, \sigma^2)$

# Hipóteses do modelo

Quando trabalhamos com **séries temporais**:

- **HST1**:  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t$ ,  $t = 1, \dots, n$
  - **HST2**: Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
  - **HST3**:  $E(u_t|X) = 0$ ,  $t = 1, \dots, n$  (implica que  $u_t$  é não correlacionado as v. explicativas em todos os períodos de tempo)
  - **HST4**: Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2$ ,  $t = 1, \dots, n$
  - **HST5**:  $\text{Corr}(u_t, u_s|X) = 0$ ,  $\forall t \neq s$  (sem correlação serial)
  - **HST6**: Os erros  $u_t$  são independentes de  $X$  e  $u_t \sim N(0, \sigma^2)$
- 
- Sob HST1–HST3,  $E(\hat{\beta}) = \beta$
  - Sob HST1–HST5,  $\hat{\beta}$  é BLUE
  - HST6, nos permite fazer inferência.

## Forma funcional e dummy

## Forma funcional e dummy

A inclusão de formas funcionais e variáveis dummy são também válidas em um contexto de séries temporais.

---

<sup>1</sup>avgcov: proporcao dos trabalhadores cobertos pela lei do salário mínimo



## Forma funcional e dummy

A inclusão de formas funcionais e variáveis dummy são também válidas em um contexto de séries temporais.

**Exemplo** Seja o modelo

$$\log(\text{prepop}_t) = \beta_0 + \beta_1 \log(\text{mincov}_t) + \beta_2 \log(\text{usgnp}_t) + u_t$$

em que

- $\text{prepop}_t$  é a taxa de empreg em Porto Rico no ano  $t$
- $\text{usgnp}_t$  é o produto nacional bruto real dos Estados Unidos
- $\text{mincov}_t = (\text{avgmin}/\text{avgwage}) * \text{avgcov}$  mede a importância dos salários mínimos em relação aos salários médios<sup>1</sup>

---

<sup>1</sup> avgcov: proporcao dos trabalhadores cobertos pela lei do salário mínimo

## Forma funcional e dummy

```
library(wooldridge)
library(dplyr)
prminwge %>% select(year,prepop, mincov,usgnp) %>% glimpse()

## Rows: 38
## Columns: 4
## $ year    <int> 1950, 1951, 1952, 1953, 1954, 1955, 1956, 1957
## $ prepop  <dbl> 0.470, 0.449, 0.434, 0.428, 0.415, 0.419, 0.412
## $ mincov  <dbl> 0.099999498, 0.10551952, 0.12078384, 0.14966875
## $ usgnp   <dbl> 1203.7, 1328.2, 1380.0, 1435.3, 1416.2, 1494.9
```

## Forma funcional e dummy

```
modelo = lm(log(prepop)~log(mincov) + log(usgnp), data = prminwge  
round(summary(modelo)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	-1.0544	0.7654	-1.3776	0.1771
##	log(mincov)	-0.1544	0.0649	-2.3797	0.0229
##	log(usgnp)	-0.0122	0.0885	-0.1377	0.8913

- O aumento em 1% em mincov, implica, em média, a diminuição de prepop em -0.1544 %
- O aumento em 1% em usgnp, implica, em média, a diminuição de prepop em -0.0122 % (porém, não é estatisticamente significativa)

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001



## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001
  - antes e depois de determinada política na empresa

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001
  - antes e depois de determinada política na empresa
  - antes e depois de determinada política pública

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001
  - antes e depois de determinada política na empresa
  - antes e depois de determinada política pública
  - etc

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001
  - antes e depois de determinada política na empresa
  - antes e depois de determinada política pública
  - etc

## Forma funcional e dummy

- Variáveis dummy são frequentemente incluídas em regressão com dados de séries temporais
- Elas são utilizadas para dividir períodos de tempo
  - posicionamento político na presidência: direita ou esquerda
  - período covid: antes do covid e depois do covid (março 12, 2020)
  - antes e depois do 11-09-2001
  - antes e depois de determinada política na empresa
  - antes e depois de determinada política pública
  - etc

Variáveis dummy nos ajudam a isolar períodos que possam ser sistematicamente diferentes de outros períodos no conjunto de dados.

## Forma funcional e dummy

**Ejemplo** Seja o modelo

$$gfr_t = \beta_0 + \beta_1 pe_t + \beta_2 ww2_t + \beta_3 pill_t + u_t$$

em que

- $gfr_t$ : taxa geral de fertilidade (crianças nascidas a cada 1000 mulheres) no ano  $t$
- $pe_t$ : taxa de dedução de impostos no ano  $t$
- $ww2_t$ : Dummy: 1 durante o tempo que os Estados Unidos estiveram envolvidos na Segunda Guerra Mundial
- $pill_t$ : Dummy: 1 desde 1963 em diante (inclusão da pílula anticoncepcional)

## Forma funcional e dummy

```
modelo = lm(gfr ~ pe + ww2 + pill, data = fertil3)
round(summary(modelo)$coef,5)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	98.68176	3.20813	30.75991	0.00000
##	pe	0.08254	0.02965	2.78417	0.00694
##	ww2	-24.23840	7.45825	-3.24988	0.00180
##	pill	-31.59403	4.08107	-7.74161	0.00000

- Na WW2, tivemos em média 24 nascimentos menos p/c 1000 mulheres
- Após a inclusão da pílula, o número de nascimento p/c 1000 mulheres diminuiu em 32.
- Um aumento de 12 USD em pe, implica no aumento, em média de  $(0.08254 \times 12 = 0.99048)$  1 nascimento a cada 1000 mulheres

# Forma funcional e dummy

O modelo anterior

$$gfr_t = \beta_0 + \beta_1 pe_t + \beta_2 ww2_t + \beta_3 pill_t + u_t$$

é um modelo estático. Mas poderíamos também usar um modelo de defasagem distribuida finita (MDDF)

$$gfr_t = \beta_0 + \beta_1 pe_t + \beta_2 pe_{t-q} + \beta_3 pe_{t-1} + \beta_4 ww2_t + \beta_5 pill_t + u_t$$



## Forma funcional e dummy

```
modelo = lm(gfr ~ pe + pe_1 + pe_2 + ww2 + pill, data = fertil3)
round(summary(modelo)$coef,5)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	95.87050	3.28196	29.21138	0.00000
## pe	0.07267	0.12553	0.57891	0.56468
## pe_1	-0.00578	0.15566	-0.03713	0.97050
## pe_2	0.03383	0.12626	0.26792	0.78962
## ww2	-22.12650	10.73197	-2.06174	0.04330
## pill	-31.30499	3.98156	-7.86250	0.00000

**Devemos confiar em essas estatísticas T?**

## Forma funcional e dummy

```
library(car)  
vif(modelo)
```

```
##           pe           pe_1           pe_2           ww2           pill  
## 22.238847 35.407682 24.092658  2.625982  1.174410
```

Suspeitamos de multicolinearidade então não podemos confiar nas estatísticas T, mas podemos fazer um teste F.

## Forma funcional e dummy

$$H_0 : \beta_{pe_t} = 0, \beta_{pe_{t-1}} = 0, \beta_{pe_{t-2}} = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdade}$$

```
summary(modelo)$fstatistic
```

```
##      value      numdf      dendf  
## 12.72844    5.00000    64.00000
```

```
qf(0.95,5,63)
```

```
## [1] 2.360684
```

Rejeitamos  $H_0$ , ou seja, pelo menos um dos  $\beta$ 's é  $\neq 0$ . Agora vamos testar  $H_0 : \beta_{pe_{t-1}} = 0, \beta_{pe_{t-2}} = 0 \quad \text{vs} \quad H_1 : H_0 \text{ não é verdade}$

## Forma funcional e dummy

```
fertil3 %>% select(pe, pe_1, pe_2) %>% glimpse()
```

```
## Rows: 72
```

```
## Columns: 3
```

```
## $ pe    <dbl> 0.00, 0.00, 0.00, 0.00, 19.27, 23.94, 20.07, 15.3
```

```
## $ pe_1  <dbl> NA, 0.00, 0.00, 0.00, 0.00, 19.27, 23.94, 20.07,
```

```
## $ pe_2  <dbl> NA, NA, 0.00, 0.00, 0.00, 0.00, 19.27, 23.94, 20
```

- Existem NA's
- **Para fazer um teste F precisamos ter o mesmo número de observações**

```
modeloi = lm(gfr ~ pe + pe_1 + pe_2 + ww2 + pill, data = fertil3)
```

```
modelor = lm(gfr ~ pe + ww2 + pill, data = fertil3)
```

```
anova(modelor,modeloi) # dará erro
```

## Forma funcional e dummy

```
# Removendo NA's
```

```
fertil = fertil3 %>% select(gfr, pe, pe_1, pe_2, ww2, pill) %>%  
  na.omit() %>% glimpse()
```

```
## Rows: 70
```

```
## Columns: 6
```

```
## $ gfr <dbl> 125.0, 123.4, 121.0, 119.8, 111.2, 117.9, 119.8,
```

```
## $ pe <dbl> 0.00, 0.00, 19.27, 23.94, 20.07, 15.33, 34.32, 36
```

```
## $ pe_1 <dbl> 0.00, 0.00, 0.00, 19.27, 23.94, 20.07, 15.33, 34
```

```
## $ pe_2 <dbl> 0.00, 0.00, 0.00, 0.00, 19.27, 23.94, 20.07, 15.3
```

```
## $ ww2 <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0
```

```
## $ pill <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0
```

## Forma funcional e dummy

```
modeloi = lm(gfr ~ pe + pe_1 + pe_2 + ww2 + pill, data = fertil)
modelor = lm(gfr ~ pe + ww2 + pill, data = fertil)
anova(modelor,modeloi)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Model 1: gfr ~ pe + ww2 + pill
```

```
## Model 2: gfr ~ pe + pe_1 + pe_2 + ww2 + pill
```

```
##   Res.Df    RSS Df Sum of Sq      F Pr(>F)
```

```
## 1      66 13054
```

```
## 2      64 13033  2    21.761 0.0534 0.948
```

```
# Não rejeitamos H0
```

# Tendência e Sazonalidade

# Tendência e Sazonalidade

Duas características presentes nas séries temporais



# Tendência e Sazonalidade

Duas características presentes nas séries temporais

## Tendência

Componente a longo prazo e pode ser modelada por uma função polinomial ou logaritmica.

# Tendência e Sazonalidade

Duas características presentes nas séries temporais

## Tendência


Componente a longo prazo e pode ser modelada por uma função polinomial ou logaritmica.

## Sazonalidade

Oscilações que se produzem e repetem em curtos periodos de tempo.

# Tendência e Sazonalidade

Exemplo de série temporal com tendência e sazonalidade



# Tendência

- Muitas séries temporais possuem uma tendência ao longo do tempo

# Tendência

- Muitas séries temporais possuem uma tendência ao longo do tempo
- Ignorar o fato que duas (ou mais) séries podem apresentar tendência na mesma direção (ou em direções opostas) pode nos levar a conclusões erradas no modelo de regressão

# Tendência

- Muitas séries temporais possuem uma tendência ao longo do tempo
- Ignorar o fato que duas (ou mais) séries podem apresentar tendência na mesma direção (ou em direções opostas) pode nos levar a conclusões erradas no modelo de regressão
- Muitas vezes podemos encontrar relações significativas e  $R^2$  próximos de 1 indicando um *aparente* bom modelo, mas na verdade esses resultados são apenas obtidos por causa que as series apresentam a mesma tendência (regressão espúria)

# Tendência

- Muitas séries temporais possuem uma tendência ao longo do tempo
- Ignorar o fato que duas (ou mais) séries podem apresentar tendência na mesma direção (ou em direções opostas) pode nos levar a conclusões erradas no modelo de regressão
- Muitas vezes podemos encontrar relações significativas e  $R^2$  próximos de 1 indicando um *aparente* bom modelo, mas na verdade esses resultados são apenas obtidos por causa que as series apresentam a mesma tendência (regressão espúria)
- Podemos *remover* a tendência incluindo na regressão uma componente de *tendência temporal*

# Tendência

**Que modelos capturam adequadamente o comportamento da tendência?**

- Tendência Linear:  $y_t = \alpha_0 + \alpha_1 t + e_t$
- Tendência Quadrática:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + e_t$
- Tendência Cúbica:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \alpha_3 t^3 + e_t$
- Tendência Exponencial:  $\log(y_t) = \alpha_0 + \alpha_1 t + e_t$  ( $y_t > 0$ )



# Tendência

**Que modelos capturam adequadamente o comportamento da tendência?**

- Tendência Linear:  $y_t = \alpha_0 + \alpha_1 t + e_t$
- Tendência Quadrática:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + e_t$
- Tendência Cúbica:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \alpha_3 t^3 + e_t$
- Tendência Exponencial:  $\log(y_t) = \alpha_0 + \alpha_1 t + e_t$  ( $y_t > 0$ )

**Como construir o modelo?**

- Incluir variáveis com tendência temporal não violam as HST1–HST6

# Tendência

## Que modelos capturam adequadamente o comportamento da tendência?

- Tendência Linear:  $y_t = \alpha_0 + \alpha_1 t + e_t$
- Tendência Quadrática:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + e_t$
- Tendência Cúbica:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \alpha_3 t^3 + e_t$
- Tendência Exponencial:  $\log(y_t) = \alpha_0 + \alpha_1 t + e_t$  ( $y_t > 0$ )

## Como construir o modelo?

- Incluir variáveis com tendência temporal não violam as HST1–HST6
- Contudo, devemos ter cuidado para não cair no caso de regressão espúria

# Tendência

## Que modelos capturam adequadamente o comportamento da tendência?

- Tendência Linear:  $y_t = \alpha_0 + \alpha_1 t + e_t$
- Tendência Quadrática:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + e_t$
- Tendência Cúbica:  $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \alpha_3 t^3 + e_t$
- Tendência Exponencial:  $\log(y_t) = \alpha_0 + \alpha_1 t + e_t$  ( $y_t > 0$ )

## Como construir o modelo?

- Incluir variáveis com tendência temporal não violam as HST1–HST6
- Contudo, devemos ter cuidado para não cair no caso de regressão espúria
- Incluir uma tendência temporal (linear, quadrática, exponencial) elimina o problema.

## Tendência: Exemplo



```
modelo = lm(gfr ~ pe + ww2 + pill, data = fertil3)
round(summary(modelo)$coef,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	98.6818	3.2081	30.7599	0.0000
## pe	0.0825	0.0296	2.7842	0.0069
## ww2	-24.2384	7.4583	-3.2499	0.0018
## pill	-31.5940	4.0811	-7.7416	0.0000

```
summary(modelo)$adj.r.squared
```

```
## [1] 0.4501837
```

# Tendência: Exemplo



## Tendência: Exemplo

```
modelo_t = lm(gfr ~ pe + ww2 + pill + t, data = fertil3)
round(summary(modelo_t)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	111.7694	3.3578	33.2868	0.0000
##	pe	0.2789	0.0400	6.9685	0.0000
##	ww2	-35.5923	6.2974	-5.6519	0.0000
##	pill	0.9974	6.2616	0.1593	0.8739
##	t	-1.1499	0.1879	-6.1195	0.0000

```
summary(modelo_t)$adj.r.squared
```

```
## [1] 0.6420465
```

## Tendência: Exemplo

```
modelo_t2 = lm(gfr ~ pe + ww2 + pill + t + I(t^2), data = fertil3)
round(summary(modelo_t2)$coef,4)
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	124.0919	4.3607	28.4566	0.0000
## pe	0.3478	0.0403	8.6392	0.0000
## ww2	-35.8803	5.7079	-6.2860	0.0000
## pill	-10.1197	6.3361	-1.5972	0.1150
## t	-2.5314	0.3894	-6.5011	0.0000
## I(t^2)	0.0196	0.0050	3.9454	0.0002

```
summary(modelo_t2)$adj.r.squared
```

```
## [1] 0.7059697
```

## Tendência : Exemplo

```
modelo_t3 = lm(gfr ~ pe + ww2 + pill + t + I(t^2) + I(t^3), data =  
round(summary(modelo_t3)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	142.7955	4.3377	32.9193	0e+00
##	pe	0.1619	0.0413	3.9198	2e-04
##	ww2	-19.0467	5.0420	-3.7776	3e-04
##	pill	-25.0097	5.3456	-4.6785	0e+00
##	t	-5.6122	0.5428	-10.3401	0e+00
##	I(t^2)	0.1554	0.0203	7.6528	0e+00
##	I(t^3)	-0.0013	0.0002	-6.8088	0e+00

```
summary(modelo_t3)$adj.r.squared
```

```
## [1] 0.8257366
```



## Tendência : Exemplo

```
modelo_t4 = lm(gfr ~ pe + ww2 + pill + t + I(t^2) + I(t^3) + I(t^4))  
round(summary(modelo_t4)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	143.6371	5.6929	25.2311	0.0000
##	pe	0.1602	0.0422	3.7940	0.0003
##	ww2	-19.2373	5.1459	-3.7384	0.0004
##	pill	-24.2481	6.3167	-3.8387	0.0003
##	t	-5.8456	1.1502	-5.0822	0.0000
##	I(t^2)	0.1709	0.0701	2.4359	0.0176
##	I(t^3)	-0.0016	0.0015	-1.0944	0.2779
##	I(t^4)	0.0000	0.0000	0.2307	0.8183

```
# summary(modelo_t4)$adj.r.squared: 0.8231607
```

# Tendência

## O que estamos fazendo quando incluímos tendencial temporal?

No fundo, o que estamos fazendo é remover a tendência das séries originais.

```
modelo_org = lm(gfr~pe + pill + t, data = fertil3)
# regressao de c/variavel sobre a tendência
modelogrf = lm(gfr~t, data = fertil3)
modelope = lm(pe~t, data = fertil3)
modelopill = lm(pill~t, data = fertil3)
# Calculamos os residuais
grf2 = residuals(modelogrf)
pe2 = residuals(modelope)
pill2 = residuals(modelopill)
```

## Tendência

podemos pensar em *grf2*, *pe2* e *pill2* como variáveis que tiveram a tendência removida. Então se fizermos

$$grf2 = \beta_0 + \beta_2 pe2 + \beta_2 pill2 + u \quad (1)$$

Os  $\hat{\beta}_1$  e  $\hat{\beta}_2$  da Eq (1), serão os mesmos  $\hat{\beta}_1$  e  $\hat{\beta}_2$  do modelo

$$grf = \beta_0 + \beta_2 pe2 + \beta_2 pill2 + \beta_3 t + u$$

## Tendência

```
modeloaux = lm(grf2~pe2 + pill2,data=fertil3)  
round(coef(modelo_org),4)
```

## (Intercept)	pe	pill	t
## 109.2111	0.1774	-2.7431	-0.8370

```
round(coef(modeloaux),4)
```

## (Intercept)	pe2	pill2
## 0.0000	0.1774	-2.7431

# Tendência

## Como saber se incluir uma tendência temporal no modelo?

- Se alguma variável (dependente ou independente) apresentar tendência, então incluir  $t$  (ou  $t^2$  ou  $t^3$ ) é uma boa ideia.

# Tendência

## Como saber se incluir uma tendência temporal no modelo?

- Se alguma variável (dependente ou independente) apresentar tendência, então incluir  $t$  (ou  $t^2$  ou  $t^3$ ) é uma boa ideia.
- Se ao incluir a tendência temporal, o termo de tendência for estatisticamente significativo e os resultados mudarem de forma substancial, os resultados sem uma tendência devem ser tratados com desconfiança.

# Tendência

## Como saber se incluir uma tendência temporal no modelo?

- Se alguma variável (dependente ou independente) apresentar tendência, então incluir  $t$  (ou  $t^2$  ou  $t^3$ ) é uma boa ideia.
- Se ao incluir a tendência temporal, o termo de tendência for estatisticamente significativo e os resultados mudarem de forma substancial, os resultados sem uma tendência devem ser tratados com desconfiança.
- Se a tendência temporal não for incluída, então não ocorrerá remoção da tendência e poderemos encontrar relações espúrias.

## Tendência: $R^2$ 's

- Os  $R^2$ 's podem ser enganosos quando trabalhamos com séries temporais.
- Precisamos ajustar os  $R^2$ 's para poder ser utilizados
- Uma forma simples consiste em fazer a regressão de  $y$  com a tendência temporal e utilizar o residual  $u = y^*$  na regressão sobre a tendência temporal e as variáveis explicativas



## Tendência: $R^2$ 's

```
summary(modelo_t)$adj.r.squared
```

```
## [1] 0.6420465
```

```
summary(modelo_t2)$adj.r.squared
```

```
## [1] 0.7059697
```

```
summary(modelo_t3)$adj.r.squared
```

```
## [1] 0.8257366
```

```
summary(modelo_t4)$adj.r.squared
```

```
## [1] 0.8231607
```

## Tendência: $R^2$ 's

```
gfr_t1 = residuals(lm(gfr~t, data = fertil3))
gfr_t2 = residuals(lm(gfr~t + I(t^2), data = fertil3))
gfr_t3 = residuals(lm(gfr~t + I(t^2) + I(t^3), data = fertil3))
gfr_t4 = residuals(lm(gfr~t + I(t^2) + I(t^3) + I(t^4), data = fertil3))

modelo_t1r = lm(gfr_t1 ~ pe + ww2 + pill + t, data = fertil3)
modelo_t2r = lm(gfr_t2 ~ pe + ww2 + pill + t + I(t^2), data = fertil3)
modelo_t3r = lm(gfr_t3 ~ pe + ww2 + pill + t + I(t^2) + I(t^3), data = fertil3)
modelo_t4r = lm(gfr_t4 ~ pe + ww2 + pill + t + I(t^2) + I(t^3) + I(t^4), data = fertil3)
```

## Tendência: $R^2$ 's

```
summary(modelo_t1r)$adj.r.squared
```

```
## [1] 0.4960654
```

```
summary(modelo_t2r)$adj.r.squared
```

```
## [1] 0.5713144
```

```
summary(modelo_t3r)$adj.r.squared
```

```
## [1] 0.4789117
```

```
summary(modelo_t4r)$adj.r.squared
```

```
## [1] 0.3786115
```

# Sazonalidade

- Número de passageiros de uma aerolinha
- Vendas de um determinado produto
- Temperatura

Algumas séries temporais exibem um padrão que se repete ao longo do tempo. Esse padrão é chamado de sazonalidade

## **Como incluir essa informação no nosso modelo de regressão?**

Variáveis dummy sazonais:

- Se tivermos dados mensais, incluir 11 variáveis dummy
- Se tivermos dados trimestrais, incluir 3 variáveis dummy
- Se tivermos dados trimestrais, incluir 2 variáveis dummy

## Sazonalidade: Exemplo

Seja o modelo

$$\log(uclms) = \beta_0 + \beta_1 ez + \beta_2 t + u$$

em que:

- $uclms$ : número de desempregados
- $ez$ : dummy (1 no período que a cidade de Anderson tinha uma zona empresarial)

## Sazonalidade: Exemplo

```
t = seq(1, nrow(ezanders))  
modelo = lm(log(uclms) ~ ez + t, data = ezanders)  
summary(modelo)$coef
```

##		Estimate	Std. Error	t value	Pr(> t )
##	(Intercept)	9.304914440	0.090212699	103.144175	1.452922e-106
##	ez	-0.371839450	0.165306482	-2.249394	2.659455e-02
##	t	-0.009336544	0.002661819	-3.507580	6.692054e-04

vamos incluir variaveis dummy para capturar o possivel efeito sazonal

## Sazonalidade

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	9.2726	0.1413	65.6186	0.0000
## factor(month)AUG	0.0541	0.1768	0.3062	0.7602
## factor(month)DEC	0.0595	0.1824	0.3259	0.7452
## factor(month)FEB	0.3382	0.1766	1.9149	0.0586
## factor(month)JAN	0.3446	0.1767	1.9506	0.0541
## factor(month)JULY	-0.1339	0.1767	-0.7581	0.4503
## factor(month)JUNE	-0.1757	0.1766	-0.9947	0.3225
## factor(month)MAR	0.2920	0.1766	1.6539	0.1015
## factor(month)MAY	-0.1431	0.1766	-0.8104	0.4198
## factor(month)NOV	-0.2694	0.1773	-1.5194	0.1321
## factor(month)OCT	-0.3813	0.1771	-2.1529	0.0339
## factor(month)SEPT	-0.3541	0.1769	-2.0014	0.0483
## ez	-0.5080	0.1457	-3.4876	0.0007


# Conclusões

- Séries temporis podem ser incluídas num contexto de modelos de regressão
- Incluir tendência temporal (Linear, Quadrática, Cúbica, Exponencial, etc) nos ajudará na modelagem e evitara que encontremos relações espúrias
- Para incorporar o efeito sazonal, podemos incluir variáveis dummy
- Muitas vezes, detectar tendência e sazonalidade não é tarefa fácil.



# Conclusões

```
dados = ts(AirPassengers, frequency = 12) #dados mensais  
plot(decompose(dados))
```



## Conclusões

Temos trabalhado sob as hipóteses

- **HST1:**  $y_t = \beta_0 + \beta_1 x_{t1} + \dots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2:** Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3:**  $E(u_t|X) = 0, t = 1, \dots, n$
- **HST4:** Homocedasticidade,  $V(u_t|X) = V(u_t) = \sigma^2, t = 1, \dots, n$
- **HST5:**  $\text{Corr}(u_t, u_s|X) = 0, \forall t \neq s$
- **HST6:** Os erros  $u_t$  são independentes de  $X$  e  $u_t \sim N(0, \sigma^2)$

Na prática, algumas dessas hipóteses podem ser irreais (em especial HST3 e HST5) e os resultados obtidos devem ser visto com cuidado.

## Leituras recomendadas

### Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 10**