

Modelos de Regressão e Previsão

Análise de regressão com dados de séries temporais II

Prof. Carlos Trucíos
carlos.trucios@facc.ufrj.br
ctruciosm.github.io

Faculdade de Administração e Ciências Contábeis
Universidade Federal do Rio de Janeiro

Aula 13

Introdução

Introdução

- **HST1:** $y_t = \beta_0 + \beta_1 x_{t1} + \cdots + \beta_k x_{tk} + u_t, t = 1, \dots, n$
- **HST2:** Não existe colinearidade perfeita entre as variáveis independentes e nenhuma das variáveis independentes é constante.
- **HST3:** $E(u_t|X) = 0, t = 1, \dots, n$
- **HST4:** Homocedasticidade, $V(u_t|X) = V(u_t) = \sigma^2, t = 1, \dots, n$
- **HST5:** $\text{Corr}(u_t, u_s|X) = 0, \forall t \neq s$
- **HST6:** Os erros u_t são independentes de X e $u_t \sim N(0, \sigma^2)$

Na última aula vimos que sob HST1–HST6 podemos incluir séries temporais num contexto de análise de regressão e ainda termos que $\hat{\beta}$ é BLUE e podemos fazer inferência como usual.

Introdução

- Contudo, algumas das hipóteses HST1–HSTT5 são irreais (em especial HST3 e HST5) e podem não ser verificadas na prática, invalidando assim as propriedades do $\hat{\beta}$

Introdução

- Contudo, algumas das hipóteses HST1–HSTT5 são irreais (em especial HST3 e HST5) e podem não ser verificadas na prática, invalidando assim as propriedades do $\hat{\beta}$
- Em amostras grandes, podemos relaxar algumas hipóteses e ainda assim garantir algumas propriedades de $\hat{\beta}$.

Introdução

- Contudo, algumas das hipóteses HST1–HSTT5 são irreais (em especial HST3 e HST5) e podem não ser verificadas na prática, invalidando assim as propriedades do $\hat{\beta}$
- Em amostras grandes, podemos relaxar algumas hipóteses e ainda assim garantir algumas propriedades de $\hat{\beta}$.
- Começaremos estudando dois conceitos necessários para aplicar as aproximações em amostras grandes com dados de séries temporais: **processo de covariância estacionária** e **séries fracamente dependentes**.

Conceitos básicos

Conceitos básicos

Processo de covariância estacionária

Um proceso estocástico $\{x_t\}_{t \geq 1}$ com $E(x_t^2) < \infty$ tem covariância estacionária se

- $E(x_t) = \mu, \quad \forall t$
- $V(x_t) = \sigma^2, \quad \forall t$
- $Cov(x_t, x_{t+h})$ depende somente de h e não de t .

Conceitos básicos

Processo de covariância estacionária

Um proceso estocástico $\{x_t\}_{t \geq 1}$ com $E(x_t^2) < \infty$ tem covariância estacionária se

- $E(x_t) = \mu, \quad \forall t$
 - $V(x_t) = \sigma^2, \quad \forall t$
 - $Cov(x_t, x_{t+h})$ depende somente de h e não de t .
-
- A média e a variância são constantes ao longo do tempo
 - Como a covariância depende somente de h , a correlação $Cor(x_t, x_{t+h})$ também depende somente de h .
 - HST3 – HST5 implicam que o erro é estacionário (média e variância constantes)

Conceitos básicos

Dependencia fraca

Uma série temporal com covariância estacionária é fracamente dependente se a $Cor(x_t, x_{t+h}) \approx 0$ rapidamente quando $h \rightarrow \infty$

- Dependência fraca é um conceito importante na análise de regressão pois ela substituirá a hipóteses de amostragem aleatoria e então conseguirmos resultados assintóticos [Não veremos isso nessa disciplina].

Séries temporais com covariância estacionária e fracamente dependentes são ideais para serem usadas num contexto de análise de regressão.

Processos MA(1) e AR(1)

Processos MA(1) e AR(1)

Processo de Média Móvel de ordem um: MA(1)

Seja a série temporal x_t que segue o seguinte processo

$$x_t = e_t + \alpha e_{t-1} \quad t = 1, 2, \dots$$

em que $e_t \sim D(0, \sigma^2)$

- $E(x_t) = 0$
- $V(x_t) = (1 + \alpha^2)\sigma^2$
- $Cov(x_t, x_{t+1}) = \alpha\sigma^2$
- $Corr(x_t, x_{t+1}) = \frac{\alpha}{1 + \alpha^2}$
- $Corr(x_t, x_{t+h}) = 0 \quad \forall h \geq 2$

Processos MA(1) e AR(1)

Processo Autorregressivo de ordem um: AR(1)

Seja a série temporal x_t que segue o seguinte processo

$$x_t = \rho x_{t-1} + e_t \quad t = 1, 2, \dots$$

em que $e_t \sim D(0, \sigma^2)$

- $E(x_t) = 0$
- $V(x_t) = \frac{\sigma^2}{1 - \rho^2} \quad (|\rho| < 1)$
- $Cov(x_t, x_{t+h}) = \rho^h V(x_t) \quad \forall h \geq 1$
- $Corr(x_t, x_{t+h}) = \rho^h$

Processos MA(1) e AR(1)

- Processos MA(1) e AR(1)¹ são bastante utilizados em séries temporais
- Podemos utilizar a função de autocorrelação para identifica-los
- Lembre-se que:



MA(1)	AR(1)
$Corr(x_t, x_{t+1}) = \frac{\alpha}{1 + \alpha^2}$	$Corr(x_t, x_{t+h}) = \rho^h$
$Corr(x_t, x_{t+h}) = 0, h \geq 2$	-

¹Em geral MA(q) e AR(p)

MA(1): função de autocorrelação

```
modelo = arima.sim(n = 1000, list(ma = 0.5))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



MA(1): função de autocorrelação

```
modelo = arima.sim(n = 1000, list(ma = -0.5))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



MA(1): função de autocorrelação

```
modelo = arima.sim(n = 1000, list(ma = 0.2))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



MA(1): função de autocorrelação

```
modelo = arima.sim(n = 1000, list(ma = -0.15))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



AR(1)

```
modelo = arima.sim(n = 1000, list(ar = 0.7))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



AR(1)

```
modelo = arima.sim(n = 1000, list(ar = -0.5))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```



Series modelo



AR(1)

```
modelo = arima.sim(n = 1000, list(ar = 0.3))  
par(mfrow = c(1,2))  
ts.plot(modelo)  
acf(modelo)
```

Series modelo



Propriedades de MQO em amostras grandes

Propriedades de MQO em amostras grandes

- HST1*: $\text{HST1} + \{(X_t, y_t) \mid t = 1, 2, \dots\}$ é estacionária e fracamente dependente.

$$y_t = \beta_0 + \beta_1 x_{t,1} + \dots + \beta_k x_{t,k} + u$$

mas dessa vez $x_{t,j}$ pode incluir defasagens da variável dependente.

Propriedades de MQO em amostras grandes

- HST1*: $\text{HST1} + \{(X_t, y_t) \mid t = 1, 2, \dots\}$ é estacionária e fracamente dependente.

$$y_t = \beta_0 + \beta_1 x_{t,1} + \dots + \beta_k x_{t,k} + u$$

mas dessa vez $x_{t,j}$ pode incluir defasagens da variável dependente.

- HST2*: HST2 (colinearidade imperfeita)

Propriedades de MQO em amostras grandes

- HST1*: $HST1 + \{(X_t, y_t) \mid t = 1, 2, \dots\}$ é estacionária e fracamente dependente.

$$y_t = \beta_0 + \beta_1 x_{t,1} + \dots + \beta_k x_{t,k} + u$$

mas dessa vez $x_{t,j}$ pode incluir defasagens da variável dependente.

- HST2*: HST2 (colinearidade imperfeita)
- HST3*: $E(u_t|X_t) = 0$ (mais fraca que HST3: $E(u_t|X) = 0$)

Propriedades de MQO em amostras grandes

- HST1*: $\text{HST1} + \{(X_t, y_t) \mid t = 1, 2, \dots\}$ é estacionária e fracamente dependente.

$$y_t = \beta_0 + \beta_1 x_{t,1} + \dots + \beta_k x_{t,k} + u$$

mas dessa vez $x_{t,j}$ pode incluir defasagens da variável dependente.

- HST2*: HST2 (colinearidade imperfeita)
- HST3*: $E(u_t|X_t) = 0$ (mais fraca que HST3: $E(u_t|X) = 0$)
- HST4*: $V(u_t|X_t) = \sigma^2$ (mais fraca que HST4: $V(u_t|X) = \sigma^2$)

Propriedades de MQO em amostras grandes

- HST1*: $HST1 + \{(X_t, y_t) \mid t = 1, 2, \dots\}$ é estacionária e fracamente dependente.

$$y_t = \beta_0 + \beta_1 x_{t,1} + \dots + \beta_k x_{t,k} + u$$

mas dessa vez $x_{t,j}$ pode incluir defasagens da variável dependente.

- HST2*: HST2 (colinearidade imperfeita)
- HST3*: $E(u_t|X_t) = 0$ (mais fraca que HST3: $E(u_t|X) = 0$)
- HST4*: $V(u_t|X_t) = \sigma^2$ (mais fraca que HST4: $V(u_t|X) = \sigma^2$)
- HST5*: $E(u_t u_s | X_t X_s) = 0 \quad \forall t \neq s$

Propriedades de MQO em amostras grandes

Consistência

Sob HST1–HST3,

$$\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$$

Normalidade assintótica do MQO

Sob algumas HST1–HST5, quando $n \rightarrow \infty$,

$$\frac{\hat{\beta} - \beta}{V(\hat{\beta})} \sim N(0, 1)$$

Não estacionariedade e não fracamente dependentes

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

- Utilizar MQO não é uma boa opção

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

- Utilizar MQO não é uma boa opção
- Podemos utilizar transformações para eliminar esse problema.

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

- Utilizar MQO não é uma boa opção
- Podemos utilizar transformações para eliminar esse problema.
- Geralmente fazer uma diferenciação $x_t - x_{t-1}$ resolve o problema²

² $\log(x_t) - \log(x_{t-1})$ também é frequentemente utilizado.

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

- Utilizar MQO não é uma boa opção
- Podemos utilizar transformações para eliminar esse problema.
- Geralmente fazer uma diferenciação $x_t - x_{t-1}$ resolve o problema²

² $\log(x_t) - \log(x_{t-1})$ também é frequentemente utilizado.

Não Estacionariedade e não fracamente dependentes

Muitas séries temporais são não estacionárias e não são fracamente dependentes

- Utilizar MQO não é uma boa opção
- Podemos utilizar transformações para eliminar esse problema.
- Geralmente fazer uma diferenciação $x_t - x_{t-1}$ resolve o problema²



Mas como vamos identificar se precisamos ou não diferenciar?

Função de autocorrelação

² $\log(x_t) - \log(x_{t-1})$ também é frequentemente utilizado.

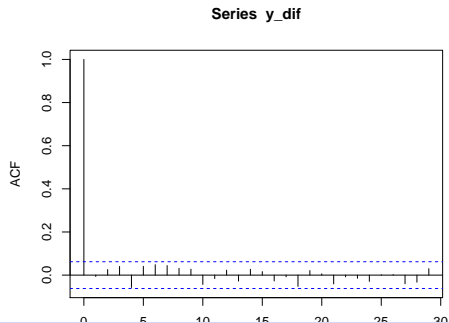

Não Estacionariedade e não fracamente dependentes

```
y = cumsum(rnorm(1000)) # Passeio aleatorio  
par(mfrow = c(1,2))  
ts.plot(y)  
acf(y)
```



Não Estacionariedade e não fracamente dependentes

```
y_dif = diff(y)
par(mfrow = c(1,2))
ts.plot(y_dif)
acf(y_dif)
```







Exemplo

Na aula anterior tínhamos feito:

```
library(wooldridge)
modelo_t2 = lm(gfr ~ pe + ww2 + pill +
               t + I(t^2), data = fertil3)
modelo_t3 = lm(gfr ~ pe + ww2 + pill +
               t + I(t^2) + I(t^3), data = fertil3)
```

Mas será que esses modelos verificam as hipóteses?

Exemplo



Exemplo

Agora vamos fazer o modelo convertendo as variáveis para estacionárias e fracamente dependentes, modelaremos:



$$\Delta gfr = \beta_0 + \beta_1 \Delta pe + u$$

```
modelo = lm(cgfr~cpe, data = fertil3)
round(summary(modelo)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t)
##	(Intercept)	-0.7848	0.5020	-1.5632	0.1226
##	cpe	-0.0427	0.0284	-1.5045	0.1370

```
summary(modelo)$adj.r.squared #0.01772896
```


Exemplo



Exemplo



```
modelo = lm(cgfr~cpe + cpe_1 + cpe_2, data = fertil3)
round(summary(modelo)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t)
##	(Intercept)	-0.9637	0.4678	-2.0602	0.0434
##	cpe	-0.0362	0.0268	-1.3522	0.1810
##	cpe_1	-0.0140	0.0276	-0.5070	0.6139
##	cpe_2	0.1100	0.0269	4.0919	0.0001

```
summary(modelo)$adj.r.squared
```

```
## [1] 0.1970524
```

Exemplo



Exemplo



```
modelo = lm(cgfr~ cpe + cpe_1 + cpe_2 + ww2 + pill, data = ferti  
round(summary(modelo)$coef,4)
```

##		Estimate	Std. Error	t value	Pr(> t)
##	(Intercept)	-0.6503	0.5818	-1.1177	0.2679
##	cpe	-0.0752	0.0324	-2.3230	0.0234
##	cpe_1	-0.0514	0.0332	-1.5495	0.1263
##	cpe_2	0.0883	0.0280	3.1546	0.0025
##	ww2	4.8392	2.8320	1.7088	0.0924
##	pill	-1.6761	1.0048	-1.6682	0.1002

```
summary(modelo)$adj.r.squared
```

```
## [1] 0.239701
```

Exemplo



Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**

Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**
- Se as autocorrelações caem lentamente, indica que o processo não é estacionário e precisamos fazer diferenciação

Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**
- Se as autocorrelações caem lentamente, indica que o processo não é estacionário e precisamos fazer diferenciação
- Outra alternativa se as séries foram estritamente positivas é $\log(x_t) - \log(x_{t-1})$

Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**
- Se as autocorrelações caem lentamente, indica que o processo não é estacionário e precisamos fazer diferenciação
- Outra alternativa se as séries foram estritamente positivas é $\log(x_t) - \log(x_{t-1})$
- As séries *diferenciadas* são utilizadas nos modelos de regressão

Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**
- Se as autocorrelações caem lentamente, indica que o processo não é estacionário e precisamos fazer diferenciação
- Outra alternativa se as séries foram estritamente positivas é $\log(x_t) - \log(x_{t-1})$
- As séries *diferenciadas* são utilizadas nos modelos de regressão
- A função de autocorrelação das séries diferenciadas podem evidenciar um processo AR(p) ou M(q) ou combinações de ambos.

Conclusões

- Quando trabalhamos com séries temporais, o gráfico da função de autocorrelação é **fundamental**
- Se as autocorrelações caem lentamente, indica que o processo não é estacionário e precisamos fazer diferenciação
- Outra alternativa se as séries foram estritamente positivas é $\log(x_t) - \log(x_{t-1})$
- As séries *diferenciadas* são utilizadas nos modelos de regressão
- A função de autocorrelação das séries diferenciadas podem evidenciar um processo AR(p) ou M(q) ou combinações de ambos.
- Diferenciar séries temporais antes de utiliza-las no modelo de regressão tem também o benefício de remover a tendência temporal linear (em lugar de incluir tendencia temporal no modelo, podemos diferencias as series com tendências obvias.)

Leituras recomendadas

Leituras recomendadas

- Wooldridge, Jeffrey M. *Introdução à Econometria: Uma abordagem moderna*. (2016). Cengage Learning. – **Cap 11**